

✓ Projeto de Análise de Dados - Titanic: Machine Learning from Disaster

1. Introdução (Definição do Problema)

1.1 Objetivo

O objetivo deste projeto é construir um pipeline completo de engenharia de dados para analisar os fatores que influenciaram a sobrevivência dos passageiros do Titanic.

Através deste trabalho, busco consolidar os conhecimentos em:

- Coleta e armazenamento de dados na nuvem
- Modelagem dimensional (Data Warehouse)
- Processos de ETL
- Análise exploratória e qualidade de dados
- Resposta a perguntas de negócios através de análise de dados

A ideia desse trabalho é procurar responder 4 perguntas sobre quais fatores influenciaram na sobrevivência. Embora houvesse algum elemento de sorte envolvido, parece que alguns grupos de pessoas tinham maior probabilidade de sobreviver do que outros.

1.2 Descrição do Problema

O problema escolhido foi o "**Titanic - Machine Learning from Disaster**" com os dados disponíveis no Kaggle. É um dataset de competição e, como nunca participei de uma competição, gostaria de iniciar com esse desafio.

Link da competição: <https://www.kaggle.com/competitions/titanic>

O naufrágio do Titanic já foi retratado em filmes e é amplamente conhecido.

Em 15 de abril de 1912, durante sua viagem inaugural, o navio RMS Titanic afundou após colidir com um iceberg. Infelizmente, não havia botes salva-vidas suficientes para todos a bordo, resultando na morte de 1.502 dos 2.224 passageiros e tripulantes.

1.3 Premissas

O dataset do Titanic, disponibilizado pelo Kaggle, contém registros sobre os passageiros do navio que naufragou em 1912, abrangendo variáveis como sexo, idade, classe da passagem, valor pago, número de familiares a bordo e porto de embarque.

A premissa adotada neste estudo é que essas características exerceram influência direta na probabilidade de sobrevivência dos indivíduos, refletindo aspectos sociais e demográficos da época.

Natureza dos dados: mistura de variáveis numéricas, categóricas e textuais.

Desafio : lidar com valores ausentes em variáveis como `Age` e `Cabin`.

1.4 Descrição do Dataset

O **Titanic – Machine Learning from Disaster**, disponibilizado na plataforma Kaggle, contém informações sobre os passageiros do navio Titanic, permitindo explorar os fatores associados à sobrevivência.

O dataset está dividido em dois arquivos principais:

- **train.csv** – utilizado para treinamento dos modelos. Inclui os dados dos passageiros, com a variável-alvo (`Survived`).
- **test.csv** – utilizado para avaliação do modelo. Contém os mesmos atributos, mas sem o rótulo de sobrevivência, sendo o objetivo prever o valor da variável-alvo.

1.4.1 Variável-alvo

Survived: indica se o passageiro sobreviveu ao naufrágio.

- `0` = não sobreviveu
- `1` = sobreviveu

1.4.2 Principais Variáveis Explicativas

- **PassengerId** – identificador único de cada passageiro
- **Pclass** – classe da passagem (1ª, 2ª ou 3ª)
- **Name** – nome do passageiro
- **Sex** – sexo (male/female)
- **Age** – idade em anos
- **SibSp** – número de irmãos/cônjuges a bordo

- **Parch** – número de pais/filhos a bordo
 - **Ticket** – número do bilhete
 - **Fare** – tarifa paga pela passagem
 - **Cabin** – cabine do passageiro (quando disponível)
 - **Embarked** – porto de embarque (C = Cherbourg, Q = Queenstown, S = Southampton)
-

1.4.3 Características do Dataset

- **Total de registros (train.csv):** 891 passageiros
 - **Número de variáveis:** 12 colunas no arquivo de treino
 - **Natureza dos dados:** mistura de variáveis numéricas, categóricas e textuais
 - **Desafio :** lidar com valores ausentes em variáveis como `Age` e `Cabin`
-

1.4.4 Perguntas de Pesquisa e Hipóteses

Este trabalho busca responder às seguintes perguntas sobre os fatores que influenciaram a sobrevivência no naufrágio do Titanic:

Pergunta 1: Qual foi a taxa geral de sobrevivência no Titanic?

Hipótese: Espera-se uma taxa de sobrevivência inferior a 50%, refletindo a gravidade do desastre e a insuficiência de botes salva-vidas para todos os passageiros a bordo.

Pergunta 2: Como a classe socioeconômica influenciou na sobrevivência?

Hipótese: Passageiros de primeira classe tiveram maior taxa de sobrevivência em relação às classes inferiores, devido à localização privilegiada de suas cabines nos decks superiores, acesso prioritário aos botes salva-vidas e maior atenção da tripulação durante a evacuação.

Pergunta 3: Qual a diferença de sobrevivência entre homens e mulheres?

Hipótese: Mulheres tiveram taxa de sobrevivência significativamente superior à dos homens, validando a aplicação do protocolo marítimo histórico "mulheres e crianças primeiro" durante a evacuação do navio.

Pergunta 4: Qual a relação entre idade e sobrevivência?

Hipótese: Passageiros mais jovens, especialmente crianças, tiveram maior taxa de sobrevivência em relação a adultos e idosos, como resultado da priorização de crianças no protocolo de evacuação e das dificuldades de mobilidade enfrentadas por pessoas mais velhas.

1.4.5 Links dos Datasets

O dataset está hospedado no GitHub, em arquivos de extensão `.csv`, podendo ser acessados através dos links públicos a seguir:

- **Base de treino:** <https://github.com/marcoantonioclpz/Marco-Currais/blob/main/train.csv>
- **Base de teste:** <https://github.com/marcoantonioclpz/Marco-Currais/blob/main/test.csv>
- **Base de validação:** <https://github.com/marcoantonioclpz/Marco-Currais/blob/main/titanic.csv>

2. PERGUNTAS DE PESQUISA

2.1 Perguntas que este trabalho busca responder

1. Qual foi a taxa geral de sobrevivência no Titanic?
2. Como a classe socioeconômica influenciou na sobrevivência?
3. Qual a diferença de sobrevivência entre homens e mulheres?
4. Qual a relação entre idade e sobrevivência?

▼ 3. Coleta de Dados

3.1 Fonte dos Dados

Os dados foram obtidos da competição "Titanic - Machine Learning from Disaster" disponível na plataforma Kaggle (<https://www.kaggle.com/competitions/titanic>). Este dataset é de domínio público e amplamente utilizado para fins educacionais, sem restrições éticas ou de confidencialidade.

3.2 Processo de Coleta

Os arquivos foram baixados diretamente do Kaggle em formato CSV:

- **train.csv:** 891 registros (dados de treino com informação de sobrevivência)
- **test.csv:** 418 registros (dados de teste para predição)

O download foi realizado através da interface web do Kaggle, após login na plataforma.

3.3 Armazenamento e Preparação no Databricks

Para viabilizar o processamento e análise dos dados, os arquivos CSV foram carregados no **Databricks Community Edition**, uma plataforma de análise de dados em nuvem baseada em Apache Spark.

Estrutura de armazenamento:

Os arquivos foram importados para o DBFS (Databricks File System) e convertidos em duas tabelas:

1. **titanic_train**: 891 registros incluindo a variável target *Survived* (indica se o passageiro sobreviveu)
2. **titanic_test**: 418 registros sem a coluna *Survived* (utilizado para validação futura)

Essa estrutura permite consultas SQL otimizadas e facilita a manipulação dos dados durante a análise exploratória.

3.4 Ambiente de Análise

Para realizar a análise exploratória, foi criado um notebook SQL no Databricks chamado "**02_Analise_SQL_Titanic**". A primeira etapa consistiu em validar o carregamento correto dos dados através de uma consulta SQL simples para contagem de registros em ambas as tabelas.

Query inicial de validação:

```
SELECT
    'Treino' AS dataset,
    COUNT(*) AS total_registros
FROM titanic_train

UNION ALL

SELECT
    'Teste' AS dataset,
    COUNT(*) AS total_registros
FROM titanic_test;
```

Table ▾ +

	A ^B _C dataset	I ² ₃ total_registros
1	Treino	891
2	Teste	418

The screenshot shows the Databricks Catalog interface. At the top, there are three tabs: 'Serverless Starter Warehouse' (selected), 'Serverless', and '2XS'. Below the tabs is a search bar with placeholder text 'Type to search...'. Underneath the search bar are two buttons: 'For you' (highlighted) and 'All'. The main area displays a hierarchical tree of datasets:

- My organization
 - workspace
 - default
 - dim_classe
 - dim_embarque
 - dim_passageiro
 - fact_sobrevivencia
 - titanic_clean
 - titanic_test**
 - titanic_train** (highlighted)
 - information_schema
 - system
 - Delta Shares Received
 - samples

The screenshot shows the Databricks SQL editor interface. The left sidebar includes links for 'New', 'Home', 'Workspace' (selected), 'Recents', 'Catalog', 'Jobs & Pipelines', 'Compute', 'Marketplace', 'SQL' (with sub-links for 'SQL Editor', 'Queries', 'Dashboards', 'Genie', 'Alerts', 'Query History', and 'SQL Warehouses'), 'Data Engineering' (with sub-links for 'Job Runs' and 'Data Ingestion'), and 'AI/ML' (with sub-link for 'Playground'). The main area has a search bar at the top and a toolbar with 'File', 'Edit', 'View', 'Run', 'Help', 'Python', 'Tabs: ON', and a status message 'Last edit was 23 hours ago'. A tab bar shows '01_Titanic_Pipeline_Dados' and '02_Analise_SQL_Titanic' (selected). The code editor contains the following SQL query:

```
%sql
-- =====
-- ANÁLISE DE QUALIDADE DOS DADOS - TITANIC
-- BLOCO 1: VERIFICAÇÃO INICIAL
-- =====

-- 1.1 Contagem total de registros
SELECT
    'Treino' AS dataset,
    COUNT(*) AS total_registros
FROM titanic_train

UNION ALL

SELECT
    'Teste' AS dataset,
    COUNT(*) AS total_registros
FROM titanic_test;
```

The results table shows the count of rows for each dataset:

dataset	total_registros
Treino	891
Teste	891

3.5 Análise dos Valores Nulos

A análise de qualidade dos dados é uma etapa fundamental em projetos de ciência de dados, pois a presença de valores ausentes pode comprometer tanto a validade das análises quanto a precisão de modelos preditivos. Por isso, foi realizada uma investigação da completude do dataset Titanic, buscando identificar e quantificar os valores nulos presentes nas variáveis.

3.6 Metodologia

Para identificar valores ausentes, foi utilizada a linguagem SQL aplicada sobre as tabelas no ambiente Databricks. A metodologia se baseia na comparação entre a contagem total de registros e a contagem de valores não-nulos em cada coluna:

Valores Nulos = COUNT(*) - COUNT(coluna)

Percentual de Nulos = (Valores Nulos / Total de Registros) × 100

Onde:

- `COUNT(*)` retorna todos os registros (incluindo nulos)
- `COUNT(coluna)` retorna apenas valores não-nulos

3.7 Resultados Obtidos

A análise do dataset de treinamento (n=891) revelou diferentes níveis de completude:

Variáveis com Ausência Crítica

Cabin (Cabine):

Apresentou 687 valores ausentes (77,1% do dataset). Essa alta taxa indica que a informação sobre cabines não foi sistematicamente registrada para a maioria dos passageiros.

Age (Idade):

Foram identificados 177 valores ausentes (19,87%). A idade é uma variável importante para análises de sobrevivência, já que as políticas de evacuação priorizavam mulheres e crianças.

Variáveis com Ausência Mínima

Embarked (Porto de Embarque):

Apenas 2 registros (0,22%) apresentaram valores ausentes. Essa taxa mínima não compromete a qualidade geral do dataset.

Variáveis Completas

As seguintes variáveis apresentaram 100% de completude:

- PassengerId (Identificador)
- Survived (Sobrevivência)
- Pclass (Classe da Passagem)
- Name (Nome)
- Sex (Sexo)
- SibSp (Irmãos/Cônjuges a Bordo)
- Parch (Pais/Filhos a Bordo)
- Ticket (Número do Bilhete)
- Fare (Tarifa Paga)

3.8 Discussão e Implicações

Os resultados mostram que o dataset tem boa qualidade geral, com 75% das variáveis (9 de 12) completamente preenchidas. No entanto, as lacunas em Cabin e Age precisam de tratamento adequado:

Variável Cabin:

Com mais de 75% de ausência, recomenda-se excluir essa variável das análises principais. Alternativamente, ela pode ser transformada em uma variável binária (tem cabine: sim/não), o que pode servir como indicador indireto de classe socioeconômica.

Variável Age:

Por ser relevante e ter ausência moderada (~20%), sugere-se aplicar técnicas de imputação usando a mediana por classe de passagem (Pclass). Isso mantém as características demográficas de cada grupo socioeconômico.

Variável Embarked:

A ausência mínima permite tratamento simples: preencher com o valor mais frequente (moda) ou excluir os 2 registros sem prejuízo significativo.

3.9 Conclusão

A análise de valores ausentes mostrou que o dataset Titanic, após o tratamento adequado das variáveis Age e Cabin, tem qualidade suficiente para análises exploratórias.

```
-- =====
-- BLOCO 2: ANÁLISE DE VALORES NULOS
-- =====

-- 2.1 Contagem de nulos por coluna no dataset de TREINO
SELECT
    'PassengerId' AS coluna,
    COUNT(*) - COUNT(PassengerId) AS valores_nulos,
    ROUND((COUNT(*) - COUNT(PassengerId)) * 100.0 / COUNT(*), 2) AS percentual_nulos
```

```
FROM titanic_train  
  
UNION ALL  
  
SELECT 'Survived', COUNT(*) - COUNT(Survived),  
       ROUND((COUNT(*) - COUNT(Survived)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Pclass', COUNT(*) - COUNT(Pclass),  
       ROUND((COUNT(*) - COUNT(Pclass)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Name', COUNT(*) - COUNT(Name),  
       ROUND((COUNT(*) - COUNT(Name)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Sex', COUNT(*) - COUNT(Sex),  
       ROUND((COUNT(*) - COUNT(Sex)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Age', COUNT(*) - COUNT(Age),  
       ROUND((COUNT(*) - COUNT(Age)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'SibSp', COUNT(*) - COUNT(SibSp),  
       ROUND((COUNT(*) - COUNT(SibSp)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Parch', COUNT(*) - COUNT(Parch),  
       ROUND((COUNT(*) - COUNT(Parch)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Ticket', COUNT(*) - COUNT(Ticket),  
       ROUND((COUNT(*) - COUNT(Ticket)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Fare', COUNT(*) - COUNT(Fare),  
       ROUND((COUNT(*) - COUNT(Fare)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Cabin', COUNT(*) - COUNT(Cabin),  
       ROUND((COUNT(*) - COUNT(Cabin)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
UNION ALL  
  
SELECT 'Embarked', COUNT(*) - COUNT(Embarked),  
       ROUND((COUNT(*) - COUNT(Embarked)) * 100.0 / COUNT(*), 2) FROM titanic_train  
  
ORDER BY valores_nulos DESC;
```

Table ▼ +

	A ^B _C coluna	1 ² ₃ valores_nulos	.00 percentual_nulos
1	Cabin	687	77.10
2	Age	177	19.87
3	Embarked	2	0.22
4	PassengerId	0	0.00
5	Survived	0	0.00
6	Pclass	0	0.00
7	Name	0	0.00
8	Sex	0	0.00
9	SibSp	0	0.00
10	Parch	0	0.00
11	Ticket	0	0.00
12	Fare	0	0.00

12 rows | 3.94s runtime

```
%sql
-- =====
-- BLOCO 2: ANÁLISE DE VALORES NULOS
-- =====

-- 2.1 Contagem de nulos por coluna no dataset de TREINO
SELECT
    'PassengerId' AS coluna,
    COUNT(*) - COUNT(PassengerId) AS valores_nulos,
    ROUND((COUNT(*) - COUNT(PassengerId)) * 100.0 / COUNT(*), 2) AS percentual_nulos
FROM titanic_train
UNION ALL

SELECT 'Survived', COUNT(*) - COUNT(Survived),
    ROUND((COUNT(*) - COUNT(Survived)) * 100.0 / COUNT(*), 2) FROM titanic_train
UNION ALL

SELECT 'Pclass', COUNT(*) - COUNT(Pclass),
    ROUND((COUNT(*) - COUNT(Pclass)) * 100.0 / COUNT(*), 2) FROM titanic_train
UNION ALL

SELECT 'Name', COUNT(*) - COUNT(Name),
```

3.10 Verificação de Registros Duplicados

3.10.1 Importância da Análise

A identificação de registros duplicados é essencial para garantir a integridade dos dados. Duplicatas podem distorcer análises estatísticas, inflacionar contagens e comprometer a validade de modelos preditivos. No contexto do dataset Titanic, cada passageiro deve possuir um identificador único (PassengerId), e a presença de duplicatas indicaria problemas na coleta ou processamento dos dados.

3.10.2 Metodologia Aplicada

Para verificar a existência de duplicatas, foi realizada uma análise comparativa entre o total de registros e o número de identificadores únicos (PassengerId). A lógica aplicada foi:

Duplicatas = Total de Registros - Quantidade de IDs Únicos

A query SQL utilizada foi:

```
SELECT
    'Verificação de PassengerId Duplicados' AS analise,
    COUNT(*) AS total_registros,
```

```
COUNT(DISTINCT PassengerId) AS ids_unicos,
COUNT(*) - COUNT(DISTINCT PassengerId) AS duplicatas
FROM titanic_train;

**Onde:**
- `COUNT(*)` retorna o total de registros
- `COUNT(DISTINCT PassengerId)` conta apenas identificadores únicos
- A subtração revela quantas duplicatas existem
```

3.10.3 Resultados Obtidos

A execução da query retornou os seguintes valores:

Análise	Total de Registros	IDs Únicos	Duplicatas
Verificação de PassengerId	891	891	0

3.10.4 Interpretação e Conclusão

A análise demonstrou que **não existem registros duplicados** no dataset de treinamento. Os 891 registros correspondem a 891 individuos.

Implicações deste resultado:

Integridade validada: O dataset mantém sua estrutura original sem redundâncias

Não requer tratamento: Não é necessário aplicar técnicas de deduplicação

Confiabilidade das análises: As contagens e estatísticas subsequentes refletirão com precisão a população de passageiros

Qualidade do dado histórico: A ausência de duplicatas indica que os registros do Titanic foram cuidadosamente preservados

Este resultado garante que as análises de sobrevivência não serão enviesados por contagens duplicadas.

▼ 3.11 Análise de Inconsistências nos Dados

3.11.1 Objetivo da Análise

Além de verificar valores ausentes e duplicatas, é fundamental identificar inconsistências que possam comprometer a qualidade das análises. Inconsistências incluem valores impossíveis (como idades negativas), valores fora do intervalo esperado (outliers extremos) ou categorias inválidas. Esta etapa garante que os dados não apenas estejam completos, mas também sejam logicamente válidos.

3.11.2 Metodologia - Análise da Variável Age (Idade)

A primeira verificação focou na variável **Age**, que representa a idade dos passageiros. Foram analisados os seguintes aspectos:

- Valores mínimos e máximos:** para identificar limites do dataset
- Média:** para entender a distribuição central
- Idades negativas:** valores impossíveis que indicariam erro de registro
- Idades acima de 100 anos:** valores suspeitos considerando a época (1912)

Query SQL utilizada:

```
SELECT
    'Age - Análise de Valores' AS analise,
    MIN(Age) AS idade_minima,
    MAX(Age) AS idade_maxima,
    ROUND(AVG(Age), 2) AS idade_media,
    COUNT(CASE WHEN Age < 0 THEN 1 END) AS idades_negativas,
    COUNT(CASE WHEN Age > 100 THEN 1 END) AS idades_suspeitas
FROM titanic_train;
```

```
%sql
-- =====
-- BLOCO 4: ANÁLISE DE INCONSISTÊNCIAS
-- =====

-- 4.1 Verificar valores de AGE (idade)
SELECT
    'Age - Análise de Valores' AS analise,
    MIN(Age) AS idade_minima,
    MAX(Age) AS idade_maxima,
    ROUND(AVG(Age), 2) AS idade_media,
    COUNT(CASE WHEN Age < 0 THEN 1 END) AS idades_negativas,
    COUNT(CASE WHEN Age > 100 THEN 1 END) AS idades_suspeitas
FROM titanic_train;
```

See performance (1)

Análise	idade_minima	idade_maxima	idade_media	idades_negativas	idades_suspeitas
Age - Análise de Valores	0.42	80	29.7	0	0

Lógica aplicada:

- `MIN(Age)` e `MAX(Age)`: identificam os extremos da distribuição
- `AVG(Age)`: calcula a média aritmética
- `COUNT(CASE WHEN Age < 0 THEN 1 END)`: conta valores negativos
- `COUNT(CASE WHEN Age > 100 THEN 1 END)`: conta valores extremos

3.11.3 Resultados Obtidos - Variável Age

A execução da query retornou:

Análise	Idade Mínima	Idade Máxima	Idade Média	Idades Negativas	Idades Suspeitas (>100)
Age - Análise de Valores	0.42	80.0	29.70	0	0

3.11.4 Interpretação dos Resultados

Idade Mínima (0.42 anos):

O valor mínimo de 0.42 anos (aproximadamente 5 meses) é plausível, representando bebês que estavam a bordo do Titanic.

Idade Máxima (80 anos):

A idade máxima de 80 anos é razoável. Não foram identificados valores extremos acima de 100 anos, o que poderia indicar erros de digitação ou registro.

Idade Média (29.70 anos):

A média de aproximadamente 30 anos reflete a demografia típica de passageiros de navios transatlânticos no início do século XX, com predominância de adultos em idade economicamente ativa.

Ausência de Inconsistências:

Zero idades negativas: não há valores impossíveis

Zero idades acima de 100: não há outliers extremos suspeitos

Intervalo coerente: todos os valores estão dentro de limites biologicamente plausíveis

3.11.5 Conclusão Parcial

A variável **Age** apresenta **consistência lógica** em seus valores. Não foram identificadas inconsistências que requeiram correção ou remoção de registros. O intervalo de 0.42 a 80 anos é compatível com a realidade histórica do Titanic, e a ausência de valores negativos ou extremos valida a qualidade do registro original dos dados.

Esta validação permite utilizar a variável **Age** com confiança nas análises de sobrevivência, especialmente considerando que políticas de evacuação priorizavam crianças e idosos.

3.11.6 Metodologia - Análise da Variável Fare (Tarifa)

A segunda verificação focou na variável **Fare**, que representa o valor pago pela passagem. Esta análise é importante porque tarifas podem indicar a classe socioeconômica dos passageiros e possíveis erros de registro. Foram verificados:

- **Valores mínimos e máximos:** para identificar o intervalo de preços
- **Média:** para entender o valor típico das passagens
- **Tarifas negativas:** valores impossíveis que indicariam erro de sistema
- **Tarifas zeradas:** possíveis tripulantes, cortesias ou erros de registro
- **Tarifas muito altas (>£500):** outliers que podem representar suítes de luxo

Query SQL utilizada:

```
SELECT
    'Fare - Análise de Valores' AS analise,
    MIN(Fare) AS tarifa_minima,
    MAX(Fare) AS tarifa_maxima,
    ROUND(AVG(Fare), 2) AS tarifa_media,
    SUM(CASE WHEN Fare < 0 THEN 1 ELSE 0 END) AS tarifas_negativas,
    SUM(CASE WHEN Fare = 0 THEN 1 ELSE 0 END) AS tarifas_zeradas,
    SUM(CASE WHEN Fare > 500 THEN 1 ELSE 0 END) AS tarifas_muito_altas
FROM titanic_train;
```

```
File Edit View Run Help Python Tabs: ON Last edit was 24 hours ago Run all Serverless Schedule Share
```

```
-- -----
-- BLOCO 4.2: ANÁLISE DE FARE (TARIFA)
-----

SELECT
    'Fare - Análise de Valores' AS analise,
    MIN(Fare) AS tarifa_minima,
    MAX(Fare) AS tarifa_maxima,
    ROUND(AVG(Fare), 2) AS tarifa_media,
    COUNT(CASE WHEN Fare < 0 THEN 1 END) AS tarifas_negativas,
    COUNT(CASE WHEN Fare = 0 THEN 1 END) AS tarifas_zeradas,
    COUNT(CASE WHEN Fare > 500 THEN 1 END) AS tarifas_muito_altas
FROM titanic_train;
```

Análise	Tarifa Mínima (£)	Tarifa Máxima (£)	Tarifa Média (£)	Tarifas Negativas	Tarifas Zeradas	Tarifas > £500
Fare - Análise de Valores	0.00	512.33	32.20	0	15	3

Lógica aplicada:

- `MIN(Fare)` e `MAX(Fare)`: identificam os extremos de preço
- `AVG(Fare)`: calcula o valor médio das passagens
- `SUM(CASE WHEN Fare < 0 ...)`: conta valores negativos impossíveis
- `SUM(CASE WHEN Fare = 0 ...)`: identifica tarifas zeradas
- `SUM(CASE WHEN Fare > 500...)`: detecta valores extremamente altos

3.11.7 Resultados Obtidos - Variável Fare

A execução da query retornou:

Análise	Tarifa Mínima (£)	Tarifa Máxima (£)	Tarifa Média (£)	Tarifas Negativas	Tarifas Zeradas	Tarifas > £500
Fare - Análise de Valores	0.00	512.33	32.20	0	15	3

3.11.8 Interpretação dos Resultados

Tarifa Mínima (£0.00):

Foram identificados 15 passageiros com tarifa zerada. Isso pode representar:

- Membros da tripulação registrados como passageiros
- Cortesias oferecidas pela companhia
- Possíveis erros de registro histórico

Tarifa Máxima (£512.33):

O valor máximo representa as suítes de luxo da primeira classe.

Tarifa Média (£32.20):

A média de aproximadamente £32 reflete a diversidade socioeconômica dos passageiros, com maioria viajando em classes mais econômicas.

Tarifas Muito Altas (3 registros acima de £500):

Estes valores representam as passagens mais caras, provavelmente de suítes de primeira classe ocupadas por passageiros de alta elite.

social. São outliers válidos, não erros.

Ausência de Valores Impossíveis:

Zero tarifas negativas: não há valores impossíveis

Intervalo coerente: valores compatíveis com preços históricos de 1912

Outliers justificáveis: tarifas altas correspondem a acomodações de luxo documentadas

3.11.9 Decisão sobre Tarifas Zeradas

Os 15 registros com tarifa zerada (1,68% do dataset) representam um caso especial. Optou-se por **mantê-los na análise** porque:

1. A quantidade é pequena e não compromete análises gerais
2. Podem representar situações reais (tripulação, cortesias)
3. A remoção poderia eliminar informações relevantes sobre sobrevivência

Caso necessário, estes registros podem ser tratados separadamente em análises específicas de correlação entre tarifa e sobrevivência.

3.11.10 Conclusão Parcial - Variável Fare

A variável **Fare** apresenta **consistência adequada** para análise. Não foram identificados valores impossíveis (negativos), e os outliers detectados são justificáveis historicamente. As tarifas zeradas, embora mereçam atenção, não comprometem a qualidade geral do dataset.

3.11.11 Metodologia - Análise de Variáveis Categóricas

Após verificar as variáveis numéricas (Age e Fare), é necessário validar as **variáveis categóricas** do dataset. Estas variáveis possuem um conjunto limitado de valores válidos, e a presença de categorias inconsistentes (como erros de digitação, valores nulos não identificados ou categorias inesperadas) pode comprometer análises e modelagens.

As variáveis categóricas analisadas foram:

- **Sex** (Sexo): deve conter apenas "male" ou "female"
- **Pclass** (Classe): deve conter apenas 1, 2 ou 3
- **Embarked** (Porto de Embarque): deve conter apenas "C", "Q" ou "S"

Análise da Variável Sex (Sexo)

A variável Sex é fundamental para análises de sobrevivência, dado que as políticas de evacuação do Titanic priorizavam mulheres ("mulheres e crianças primeiro"). Foi realizada uma verificação para garantir que apenas valores válidos estejam presentes.

Query SQL utilizada:

```
SELECT
    'Sex - Valores Únicos' AS analise,
    Sex AS valor,
    COUNT(*) AS quantidade
FROM titanic_train
GROUP BY Sex
ORDER BY quantidade DESC;
```

```
▶ ✓ Dec 10, 2025 (2s) 6
%sql
-- =====
-- BLOCO 4.3: ANÁLISE DE VARIÁVEIS CATEGÓRICAS
-- =====

-- 4.3.1 Verificar valores válidos em SEX (Sexo)
SELECT
    'Sex - Valores Únicos' AS analise,
    Sex AS valor,
    COUNT(*) AS quantidade
FROM titanic_train
GROUP BY Sex
ORDER BY quantidade DESC;

> See performance (1) Optimize
```

	analise	valor	quantidade
1	Sex - Valores Únicos	male	577
2	Sex - Valores Únicos	female	314

Lógica aplicada:

- `GROUP BY Sex`: agrupa registros por valor único da coluna
- `COUNT(*)`: conta quantos passageiros existem em cada categoria
- `ORDER BY quantidade DESC`: ordena do mais frequente para o menos frequente

▼ 3.11.12 Resultados Obtidos - Variável Sex

A execução da query retornou:

Análise	Valor	Quantidade
Sex - Valores Únicos	male	577
Sex - Valores Únicos	female	314

3.11.13 Interpretação dos Resultados - Variável Sex

Valores Identificados:

Foram encontrados apenas dois valores distintos: "**male**" (masculino) e "**female**" (feminino), que são as categorias esperadas e válidas para esta variável.

Distribuição:

- **Homens**: 577 passageiros (64,8% do total)
- **Mulheres**: 314 passageiras (35,2% do total)

Validação de Consistência:

Apenas valores válidos: não há categorias inesperadas

Sem erros de digitação: não foram encontradas variações como "M", "F", "Male", "MALE"

Sem valores nulos: todos os 891 registros estão categorizados ($577 + 314 = 891$)

Padronização adequada: formato consistente em minúsculas

3.11.14 Conclusão Parcial - Variável Sex

A variável **Sex** está **totalmente consistente** e pronta para uso em análises. A ausência de valores inválidos, a padronização adequada e a completude dos dados garantem que esta variável pode ser utilizada com confiança em análises de sobrevivência por gênero, que são centrais para compreender os padrões de evacuação do Titanic.

▼ Análise da Variável Pclass (Classe da Passagem)

A variável **Pclass** representa a classe socioeconômica da passagem adquirida, dividida em três categorias: 1ª classe (mais cara e luxuosa), 2ª classe (intermediária) e 3ª classe (mais econômica). Esta variável é crucial para análises de sobrevivência, pois a localização das cabines e o acesso aos botes salva-vidas variavam significativamente entre as classes.

Query SQL utilizada:

```
SELECT
    'Pclass - Valores Únicos' AS analise,
    Pclass AS valor,
    COUNT(*) AS quantidade
FROM titanic_train
GROUP BY Pclass
ORDER BY Pclass;
```

```
%sql
-- 4.3.2 Verificar valores válidos em PCLASS (Classe)
SELECT
    'Pclass - Valores Únicos' AS analise,
    Pclass AS valor,
    COUNT(*) AS quantidade
FROM titanic_train
GROUP BY Pclass
ORDER BY Pclass;
```

▶ See performance (1)

Table +

	A ^B C analise	I ² ₃ valor	I ² ₃ quantidade
1	Pclass - Valores Únicos	1	216
2	Pclass - Valores Únicos	2	184
3	Pclass - Valores Únicos	3	491

Lógica aplicada:

- `GROUP BY Pclass`: agrupa registros por classe
- `COUNT(*)`: conta passageiros em cada classe
- `ORDER BY Pclass`: ordena da 1^a para a 3^a classe

Resultados Obtidos - Variável Pclass

A execução da query retornou:

Análise	Valor	Quantidade
Pclass - Valores Únicos	1	216
Pclass - Valores Únicos	2	184
Pclass - Valores Únicos	3	491

Interpretação dos Resultados - Variável Pclass

Valores Identificados:

Foram encontrados apenas três valores distintos: **1, 2 e 3**, que correspondem exatamente às três classes de passagem disponíveis no Titanic.

Distribuição:

- **1^a Classe**: 216 passageiros (24,2% do total)
- **2^a Classe**: 184 passageiros (20,7% do total)
- **3^a Classe**: 491 passageiros (55,1% do total)

Esta distribuição é coerente, com a maioria dos passageiros viajando em 3^a classe, que era a opção mais acessível.

Validação de Consistência:

Apenas valores válidos: somente 1, 2 e 3

Sem valores fora do intervalo: não há classe 0, 4 ou outros valores impossíveis

Sem valores nulos: todos os 891 registros estão categorizados ($216 + 184 + 491 = 891$)

Tipo de dado adequado: valores numéricos inteiros

Conclusão Parcial - Variável Pclass

A variável **Pclass** apresenta **perfeita consistência** e está pronta para análises.

Análise da Variável Embarked (Porto de Embarque)

A variável **Embarked** indica o porto onde cada passageiro embarcou no Titanic. Os valores válidos são:

- **C** = Cherbourg (França)
- **Q** = Queenstown (Irlanda, atual Cobh)

- **S** = Southampton (Inglaterra)

Esta variável pode ter relevância para análises de sobrevivência, pois diferentes portos tinham perfis socioeconômicos distintos de passageiros.

Query SQL utilizada:

```
SELECT
    'Embarked - Valores Únicos' AS analise,
    Embarked AS valor,
    COUNT(*) AS quantidade
FROM titanic_train
GROUP BY Embarked
ORDER BY quantidade DESC;
```

Lógica aplicada:

- `GROUP BY Embarked`: agrupa registros por porto de embarque
- `COUNT(*)`: conta passageiros de cada porto
- `ORDER BY quantidade DESC`: ordena do mais frequente para o menos frequente

Resultados Obtidos - Variável Embarked

A execução da query retornou:

Análise	Valor	Quantidade
Embarked - Valores Únicos	S	644
Embarked - Valores Únicos	C	168
Embarked - Valores Únicos	Q	77
Embarked - Valores Únicos	NULL	2

Interpretação dos Resultados - Variável Embarked

Valores Identificados:

Foram encontrados os três valores esperados (**S**, **C**, **Q**) mais 2 registros com valores nulos.

Distribuição:

- **Southampton (S)**: 644 passageiros (72,3% do total) - porto principal de partida
- **Cherbourg (C)**: 168 passageiros (18,9% do total) - primeira parada na França
- **Queenstown (Q)**: 77 passageiros (8,6% do total) - última parada antes do Atlântico
- **Valores Nulos**: 2 passageiros (0,2% do total)

A predominância de Southampton é esperada, pois era o porto de origem da viagem inaugural do Titanic.

Validação de Consistência:

Apenas valores válidos: somente C, Q e S (além dos 2 nulos já identificados)

Sem erros de digitação: não há variações como "Cherbourg", "s", "Southampton"

Padronização adequada: formato consistente em letra maiúscula

Valores nulos já conhecidos: os 2 registros nulos foram previamente identificados na análise de valores ausentes (seção 3.7)

Tratamento dos Valores Nulos:

Como já discutido na seção 3.8, os 2 registros com porto de embarque ausente representam apenas 0,2% do dataset e podem ser facilmente tratados através de imputação com a moda (Southampton) ou remoção, sem prejuízo significativo às análises.

Conclusão Parcial - Variável Embarked

A variável **Embarked** está **consistente** e contém apenas valores válidos (além dos 2 nulos já documentados).

▼ 3.12 Análise Estatística Descritiva

3.12.1 Objetivo da Análise

Após validar a qualidade e consistência dos dados, é fundamental compreender as características estatísticas das variáveis numéricas. A análise descritiva permite identificar padrões centrais, dispersão dos dados e características da distribuição, fornecendo uma visão quantitativa do perfil dos passageiros do Titanic.

3.12.2 Metodologia

Foram calculadas medidas de tendência central e dispersão para as principais variáveis numéricas do dataset:

- **Age** (Idade): idade dos passageiros em anos
- **Fare** (Tarifa): valor pago pela passagem em libras esterlinas (£)

- **SibSp** (Siblings/Spouses): número de irmãos ou cônjuges a bordo
- **Parch** (Parents/Children): número de pais ou filhos a bordo

Medidas estatísticas calculadas:

- **Mínimo e Máximo**: valores extremos da distribuição
- **Média**: medida de tendência central (soma dos valores / quantidade)
- **Mediana**: valor central que divide a distribuição ao meio (50º percentil)
- **Desvio Padrão**: medida de dispersão que indica o quanto os valores se afastam da média

Query SQL utilizada:

```

SELECT
    'Age' AS variavel,
    COUNT(Age) AS total_valores,
    ROUND(MIN(Age), 2) AS minimo,
    ROUND(MAX(Age), 2) AS maximo,
    ROUND(AVG(Age), 2) AS media,
    ROUND(PERCENTILE(Age, 0.5), 2) AS mediana,
    ROUND(STDDEV(Age), 2) AS desvio_padrao
FROM titanic_train
UNION ALL
SELECT
    'Fare' AS variavel,
    COUNT(Fare) AS total_valores,
    ROUND(MIN(Fare), 2) AS minimo,
    ROUND(MAX(Fare), 2) AS maximo,
    ROUND(AVG(Fare), 2) AS media,
    ROUND(PERCENTILE(Fare, 0.5), 2) AS mediana,
    ROUND(STDDEV(Fare), 2) AS desvio_padrao
FROM titanic_train
UNION ALL
SELECT
    'SibSp' AS variavel,
    COUNT(SibSp) AS total_valores,
    ROUND(MIN(SibSp), 2) AS minimo,
    ROUND(MAX(SibSp), 2) AS maximo,
    ROUND(AVG(SibSp), 2) AS media,
    ROUND(PERCENTILE(SibSp, 0.5), 2) AS mediana,
    ROUND(STDDEV(SibSp), 2) AS desvio_padrao
FROM titanic_train
UNION ALL
SELECT
    'Parch' AS variavel,
    COUNT(Parch) AS total_valores,
    ROUND(MIN(Parch), 2) AS minimo,
    ROUND(MAX(Parch), 2) AS maximo,
    ROUND(AVG(Parch), 2) AS media,
    ROUND(PERCENTILE(Parch, 0.5), 2) AS mediana,
    ROUND(STDDEV(Parch), 2) AS desvio_padrao
FROM titanic_train;

```

```
%sql
-- =====
-- BLOCO 5: ESTATÍSTICAS DESCRIPTIVAS
-- =====

-- 5.1 Estatísticas completas das variáveis numéricas
SELECT
    'Age' AS variavel,
    COUNT(Age) AS total_valores,
    ROUND(MIN(Age), 2) AS minimo,
    ROUND(MAX(Age), 2) AS maximo,
    ROUND(AVG(Age), 2) AS media,
    ROUND(PERCENTILE(Age, 0.5), 2) AS mediana,
    ROUND(STDEV(Age), 2) AS desvio_padrao
FROM titanic_train

UNION ALL

SELECT
    'Fare' AS variavel,
    COUNT(Fare) AS total_valores,
    ROUND(MIN(Fare), 2) AS minimo,
    ROUND(MAX(Fare), 2) AS maximo,
    ROUND(AVG(Fare), 2) AS media,
    ROUND(PERCENTILE(Fare, 0.5), 2) AS mediana,
    ROUND(STDEV(Fare), 2) AS desvio_padrao
FROM titanic_train
```

3.12.3 Resultados Obtidos

A execução da query retornou as seguintes estatísticas:

Variável	Total de Valores	Mínimo	Máximo	Média	Mediana	Desvio Padrão
Age	714	0.42	80.00	29.70	28.00	14.53
Fare	891	0.00	512.33	32.20	14.45	49.69
SibSp	891	0.00	8.00	0.52	0.00	1.10
Parch	891	0.00	6.00	0.38	0.00	0.81

3.12.4 Interpretação dos Resultados

Análise da Variável Age (Idade)

Tendência Central:

- Média:** 29,70 anos indica uma população relativamente jovem
- Mediana:** 28,00 anos (próxima à média, sugerindo distribuição relativamente simétrica)

Dispersão:

- Intervalo:** 0,42 a 80 anos (ampla faixa etária, de bebês a idosos)
- Desvio Padrão:** 14,53 anos indica variabilidade moderada

Observação: Apenas 714 dos 891 registros possuem idade (19,87% de valores ausentes, conforme identificado na seção 3.7).

Análise da Variável Fare (Tarifa)

Tendência Central:

- Média:** £32,20 (influenciada por valores extremos)
- Mediana:** £14,45 (valor típico, bem inferior à média)

Dispersão:

- Intervalo:** £0,00 a £512,33 (amplitude muito grande)
- Desvio Padrão:** £49,69 (alta dispersão, indicando grande variabilidade)

Interpretação: A diferença entre média (£32,20) e mediana (£14,45) indica **distribuição assimétrica positiva** (assimetria à direita), com poucos valores muito altos (passagens de luxo) puxando a média para cima. A maioria dos passageiros pagou valores mais baixos.

Análise da Variável SibSp (Irmãos/Cônjuges)

Tendência Central:

- Média:** 0,52 (menos de 1 acompanhante em média)

- **Mediana:** 0,00 (metade dos passageiros viajava sem irmãos/cônjuges)

Dispersão:

- **Intervalo:** 0 a 8 (máximo de 8 irmãos/cônjuges a bordo)
- **Desvio Padrão:** 1,10 (baixa dispersão)

Interpretação: A maioria dos passageiros viajava **sozinha ou com poucos familiares** deste tipo. O valor máximo de 8 representa casos raros de famílias muito grandes.

Análise da Variável Parch (Pais/Filhos)

Tendência Central:

- **Média:** 0,38 (menos de 1 acompanhante em média)
- **Mediana:** 0,00 (metade dos passageiros viajava sem pais/filhos)

Dispersão:

- **Intervalo:** 0 a 6 (máximo de 6 pais/filhos a bordo)
- **Desvio Padrão:** 0,81 (baixa dispersão)

Interpretação: Similar a SibSp, a maioria viajava **sem pais ou filhos**. O perfil típico era de adultos viajando sozinhos ou em casais.

3.12.5 Análise Comparativa

Perfil Demográfico Geral:

- **Idade:** População adulta jovem (média ~30 anos)
- **Situação Familiar:** Maioria viajando sozinha ou com poucos acompanhantes
- **Classe Social:** Grande variação (tarifas de £0 a £512), com predominância de passagens mais baratas

Assimetrias Identificadas:

- **Fare:** Forte assimetria positiva (poucos muito ricos, muitos com recursos limitados)
- **SibSp e Parch:** Assimetria positiva (maioria sem acompanhantes, poucos com famílias grandes)
- **Age:** Distribuição mais equilibrada (simétrica)

3.12.6 Conclusão

A análise estatística descritiva revelou um perfil diversificado de passageiros, com predominância de adultos jovens viajando com poucos ou nenhum familiar. A grande variação nas tarifas reflete a estratificação socioeconômica característica da época.

Estas estatísticas fornecem a base quantitativa necessária para as análises exploratórias subsequentes, especialmente para investigar como idade, classe social e composição familiar influenciaram as taxas de sobrevivência no naufrágio do Titanic.

```

TITANIC_PIPELINE_DADOS 02_Analise_SQL_Titanic + 
File Edit View Run Help Python Tabs: ON Last edit was 24 hours ago Run all Serverless Schedule 
Dec 10, 2025 (2s) 8

UNION ALL

SELECT
    'Parch' AS variavel,
    COUNT(Parch) AS total_valores,
    ROUND(MIN(Parch), 2) AS minimo,
    ROUND(MAX(Parch), 2) AS maximo,
    ROUND(AVG(Parch), 2) AS media,
    ROUND(PERCENTILE(Parch, 0.5), 2) AS mediana,
    ROUND(STDEV(Parch), 2) AS desvio_padrao
FROM titanic_train;

> See performance (1) Optimize
Table + 
A B variavel 1 2 3 total_valores 1.2 minimo 1.2 maximo 1.2 media 1.2 mediana 1.2 desvio_padrao
1 Age 714 0.42 80 29.7 28 14.53
2 Fare 891 0 512.33 32.2 14.45 49.69
3 SibSp 891 0 8 0.52 0 1.1
4 Parch 891 0 6 0.38 0 0.81

```

✓ 4. ANÁLISE EXPLORATÓRIA - PERGUNTAS DE PESQUISA

Após validar a qualidade dos dados e compreender suas características estatísticas, esta seção apresenta análises específicas para responder às principais questões sobre os fatores que influenciaram a sobrevivência no naufrágio do Titanic.

4.1 Pergunta 1: Qual foi a taxa geral de sobrevivência no Titanic?

4.1.1 Objetivo

Determinar a proporção de passageiros que sobreviveram ao naufrágio, estabelecendo uma linha de base para comparações posteriores entre diferentes grupos demográficos e socioeconômicos.

4.1.2 Metodologia

Foi realizada uma contagem simples dos registros agrupados pela variável **Survived**, que indica se o passageiro sobreviveu (1) ou não (0). O percentual foi calculado dividindo a quantidade de cada grupo pelo total de passageiros.

Query SQL utilizada:

```
SELECT
    Survived,
    COUNT() AS quantidade,
    ROUND(COUNT() * 100.0 / (SELECT COUNT(*) FROM titanic_train), 2) AS percentual
FROM titanic_train
GROUP BY Survived
ORDER BY Survived;
```

The screenshot shows a Jupyter Notebook cell with the following content:

```
%sql
-- =====
-- PERGUNTA 1: QUAL A TAXA GERAL DE SOBREVIVÊNCIA?
-- =====

SELECT
    Survived,
    COUNT(*) AS quantidade,
    ROUND(COUNT(*) * 100.0 / (SELECT COUNT(*) FROM titanic_train), 2) AS percentual
FROM titanic_train
GROUP BY Survived
ORDER BY Survived;
```

Below the code, there is a table output:

	Survived	quantidade	percentual
1	0	549	61.62
2	1	342	38.38

Lógica aplicada:

- `GROUP BY Survived`: separa passageiros em dois grupos (0 = não sobreviveu, 1 = sobreviveu)
- `COUNT(*)`: conta o número de passageiros em cada grupo
- `COUNT(*) * 100.0 / (SELECT COUNT(*) FROM titanic_train)`: calcula o percentual sobre o total

4.1.3 Resultados Obtidos

A execução da query retornou:

Survived	Status	Quantidade	Percentual (%)
0	Não Sobreviveu	549	61.62
1	Sobreviveu	342	38.38

Total de passageiros analisados: 891

4.1.4 Interpretação dos Resultados

Taxa de Mortalidade:

Do total de 891 passageiros no dataset de treinamento, **549 pessoas não sobreviveram** ao naufrágio, representando **61,62%** do total. Esta é uma taxa de mortalidade extremamente alta, refletindo a gravidade do desastre.

Taxa de Sobrevida:

Apenas **342 passageiros sobreviveram**, correspondendo a **38,38%** do total. Isso significa que **menos de 2 em cada 5 passageiros conseguiram escapar** do naufrágio.

4.1.5 Conclusão

A taxa geral de sobrevivência de **38,38%** estabelece a linha de base para as análises subsequentes. Este valor representa a média geral, mas é esperado que diferentes grupos (por classe, sexo, idade, etc.) apresentem taxas significativamente diferentes, refletindo as desigualdades no acesso aos recursos de salvamento durante a tragédia.

✓ 4.2 Pergunta 2: Como a classe socioeconômica influenciou na sobrevivência?

4.2.1 Objetivo

Investigar se a classe da passagem (Pclass) teve impacto nas chances de sobrevivência, verificando se passageiros de primeira classe tiveram vantagens em relação às classes inferiores durante a evacuação do navio.

4.2.2 Metodologia

Foi realizada uma análise comparativa das taxas de sobrevivência entre as três classes de passagem (1ª, 2ª e 3ª classe). Para cada classe, foram calculados:

- Total de passageiros
- Quantidade de sobreviventes
- Quantidade de não sobreviventes
- Taxa percentual de sobrevivência

Query SQL utilizada:

```
SELECT
    Pclass,
    COUNT() AS total_passageiros,
    SUM(CASE WHEN Survived = 1 THEN 1 ELSE 0 END) AS sobreviventes,
    SUM(CASE WHEN Survived = 0 THEN 1 ELSE 0 END) AS nao_sobreviventes,
    ROUND(SUM(CASE WHEN Survived = 1 THEN 1 ELSE 0 END) * 100.0 / COUNT(), 2) AS taxa_sobrevivencia
FROM titanic_train
GROUP BY Pclass
ORDER BY Pclass;
```

Pclass	total_passageiros	sobreviventes	nao_sobreviventes	taxa_sobrevivencia
1	216	136	80	62.96
2	184	87	97	47.28
3	491	119	372	24.24

Lógica aplicada:

- `GROUP BY Pclass`: agrupa dados por classe (1, 2 ou 3)
- `SUM(CASE WHEN Survived = 1...)`: conta sobreviventes em cada classe
- `SUM(CASE WHEN Survived = 0...)`: conta não sobreviventes em cada classe
- Cálculo percentual: (sobreviventes / total) × 100

4.2.3 Resultados Obtidos

A execução da query retornou:

Classe	Total de Passageiros	Sobreviventes	Não Sobreviventes	Taxa de Sobrevivência (%)
1ª Classe	216	136	80	62.96

Classe	Total de Passageiros	Sobreviventes	Não Sobreviventes	Taxa de Sobrevivência (%)
2ª Classe	184	87	97	47.28
3ª Classe	491	119	372	24.24

4.2.4 Interpretação dos Resultados

1ª Classe - Taxa de Sobrevivência: 62,96%

Análise:

- Dos 216 passageiros de primeira classe, **136 sobreviveram** (62,96%)
- Taxa **64% superior à média geral** (38,38%)
- Mais de **6 em cada 10** passageiros de primeira classe sobreviveram

2ª Classe - Taxa de Sobrevivência: 47,28%

Análise:

- Dos 184 passageiros de segunda classe, **87 sobreviveram** (47,28%)
- Taxa **23% superior à média geral**, mas inferior à primeira classe
- Aproximadamente **metade dos passageiros** sobreviveu

3ª Classe - Taxa de Sobrevivência: 24,24%

Análise:

- Dos 491 passageiros de terceira classe, apenas **119 sobreviveram** (24,24%)
- Taxa **37% inferior à média geral**
- Apenas **1 em cada 4** passageiros de terceira classe sobreviveu
- **372 pessoas não sobreviveram** - o maior número absoluto de mortes

4.2.5 Análise Comparativa

Diferença entre extremos:

- Passageiros de **1ª classe** tiveram **2,6 vezes mais chances** de sobreviver em relação aos de **3ª classe** (62,96% vs 24,24%)
- Diferença absoluta de **38,72 pontos percentuais** entre primeira e terceira classe

Gradiente de sobrevivência:

- Observa-se uma **correlação inversa clara** entre classe social e mortalidade
- Quanto menor a classe, menor a taxa de sobrevivência
- A progressão é consistente: 1ª (62,96%) > 2ª (47,28%) > 3ª (24,24%)

4.2.6 Conclusão

A análise demonstra que **a classe socioeconômica foi um fator determinante para a sobrevivência** no naufrágio do Titanic. Passageiros de primeira classe tiveram chances significativamente superiores de sobreviver, enquanto os de terceira classe enfrentaram as piores condições.

Principais achados: Forte correlação entre classe social e sobrevivência

Desigualdade extrema: diferença de 38,72 pontos percentuais entre 1ª e 3ª classe

Gradiente consistente: taxa de sobrevivência diminui progressivamente da 1ª para a 3ª classe

Esta análise reforça a narrativa histórica de que o desastre do Titanic não foi apenas uma tragédia marítima, mas também um reflexo das profundas divisões sociais do período.

▼ 4.3 Pergunta 3: Qual a diferença de sobrevivência entre homens e mulheres?

4.3.1 Objetivo

Investigar o impacto do sexo na taxa de sobrevivência, verificando se o protocolo histórico "mulheres e crianças primeiro" foi efetivamente aplicado durante a evacuação do Titanic.

4.3.2 Metodologia

Foi realizada uma análise comparativa das taxas de sobrevivência entre passageiros do sexo masculino e feminino. Para cada grupo, foram calculados:

- Total de passageiros
- Quantidade de sobreviventes
- Quantidade de não sobreviventes
- Taxa percentual de sobrevivência

Query SQL utilizada:

```

SELECT
    Sex,
    COUNT() AS total_passageiros,
    SUM(CASE WHEN Survived = 1 THEN 1 ELSE 0 END) AS sobreviventes,
    SUM(CASE WHEN Survived = 0 THEN 1 ELSE 0 END) AS nao_sobreviventes,
    ROUND(SUM(CASE WHEN Survived = 1 THEN 1 ELSE 0 END) * 100.0 / COUNT(), 2) AS taxa_sobrevivencia
FROM titanic_train
GROUP BY Sex
ORDER BY taxa_sobrevivencia DESC;

```

The screenshot shows a Jupyter Notebook interface with the following details:

- Title:** 02_Analise_SQL_Titanic
- Code:**

```

-- PERGUNTA 3: DIFERENÇA DE SOBREVIVÊNCIA ENTRE HOMENS E MULHERES
-- =====

SELECT
    Sex,
    COUNT(*) AS total_passageiros,
    SUM(CASE WHEN Survived = 1 THEN 1 ELSE 0 END) AS sobreviventes,
    SUM(CASE WHEN Survived = 0 THEN 1 ELSE 0 END) AS nao_sobreviventes,
    ROUND(SUM(CASE WHEN Survived = 1 THEN 1 ELSE 0 END) * 100.0 / COUNT(*), 2) AS taxa_sobrevivencia
FROM titanic_train
GROUP BY Sex
ORDER BY taxa_sobrevivencia DESC;

```
- Table Output:**

	Sex	total_passageiros	sobreviventes	nao_sobreviventes	taxa_sobrevivencia
1	female	314	233	81	74.20
2	male	577	109	468	18.89

Lógica aplicada:

- `GROUP BY Sex`: separa dados por sexo (male/female)
- `SUM(CASE WHEN Survived = 1...)`: conta sobreviventes de cada sexo
- Cálculo percentual para comparação direta

4.3.3 Resultados Obtidos

A execução da query retornou:

Sexo	Total de Passageiros	Sobreviventes	Não Sobreviventes	Taxa de Sobrevivência (%)
Feminino (female)	314	233	81	74.20
Masculino (male)	577	109	468	18.89

4.3.4 Interpretação dos Resultados

Mulheres - Taxa de Sobrevivência: 74,20%

Análise:

- Das 314 mulheres a bordo, **233 sobreviveram** (74,20%)
- Taxa **93% superior à média geral** (38,38%)
- Aproximadamente **3 em cada 4 mulheres** sobreviveram
- Apenas **81 mulheres não sobreviveram** (25,80%)

Homens - Taxa de Sobrevivência: 18,89%

Análise:

- Dos 577 homens a bordo, apenas **109 sobreviveram** (18,89%)
- Taxa **51% inferior à média geral**
- Apenas **1 em cada 5 homens** sobreviveu
- **468 homens não sobreviveram** (81,11%) - a grande maioria

4.3.5 Análise Comparativa

Diferença dramática entre os sexos:

- Mulheres tiveram **3,93 vezes mais chances** de sobreviver em relação aos homens (74,20% vs 18,89%)
- Diferença absoluta de **55,31 pontos percentuais**
- Esta é a **maior diferença observada** entre todos os fatores analisados até o momento

Comparação com a média geral:

- **Mulheres:** +35,82 pontos acima da média (74,20% vs 38,38%)
- **Homens:** -19,49 pontos abaixo da média (18,89% vs 38,38%)

4.3.6 Análise de Distribuição**Composição demográfica:**

- **Homens:** 577 passageiros (64,76% do total) - maioria absoluta
- **Mulheres:** 314 passageiras (35,24% do total) - minoria

Paradoxo da sobrevivência: Apesar de serem **minoria numérica** (35% dos passageiros), as mulheres representaram a **maioria dos sobreviventes** (233 de 342 sobreviventes = 68,13%).

Impacto absoluto:

- **233 mulheres salvas** de 314 (74,20%)
- **109 homens salvos** de 577 (18,89%)
- O número absoluto de mulheres salvas foi **mais que o dobro** do número de homens salvos, apesar de haver quase o dobro de homens a bordo

4.3.7 Conclusão

A análise demonstra que **o sexo foi o fator mais determinante para a sobrevivência** no naufrágio do Titanic, superando até mesmo a classe socioeconômica em termos de impacto.

Principais achados: Diferença extrema: 55,31 pontos percentuais entre homens e mulheres

Protocolo efetivo: "mulheres e crianças primeiro" foi rigorosamente aplicado

Inversão demográfica: mulheres eram minoria a bordo, mas maioria entre sobreviventes

▼ **4.4 Pergunta 4: Qual a relação entre idade e sobrevivência?**

4.4.1 Objetivo

Investigar se a idade dos passageiros influenciou suas chances de sobrevivência, verificando se o protocolo "mulheres e crianças primeiro" resultou em maior taxa de sobrevivência para passageiros mais jovens.

4.4.2 Metodologia

Foi realizada uma análise comparativa das estatísticas de idade entre passageiros que sobreviveram e os que não sobreviveram. Para cada grupo, foram calculadas medidas de tendência central e dispersão:

- Quantidade de registros com idade informada
- Idade mínima e máxima
- Idade média
- Idade mediana

Query SQL utilizada:

```
SELECT
    CASE WHEN Survived = 1 THEN 'Sobreviveu' ELSE 'Não Sobreviveu' END AS status,
    COUNT(Age) AS total_com_idade,
    ROUND(MIN(Age), 2) AS idade_minima,
    ROUND(MAX(Age), 2) AS idade_maxima,
    ROUND(AVG(Age), 2) AS idade_media,
    ROUND(PERCENTILE(Age, 0.5), 2) AS idade_mediana
FROM titanic_train
WHERE Age IS NOT NULL
GROUP BY Survived
ORDER BY Survived DESC;
```

```
-- =====
-- PERGUNTA 4: RELAÇÃO ENTRE IDADE E SOBREVIVÊNCIA
-- =====

-- 4.1 Estatísticas de idade por status de sobrevivência
SELECT
CASE WHEN Survived = 1 THEN 'Sobreviveu' ELSE 'Não Sobreviveu' END AS status,
COUNT(Age) AS total_com_idade,
ROUND(MIN(Age), 2) AS idade_minima,
ROUND(MAX(Age), 2) AS idade_maxima,
ROUND(AVG(Age), 2) AS idade_media,
ROUND(PERCENTILE(Age, 0.5), 2) AS idade_mediana
FROM titanic_train
WHERE Age IS NOT NULL
GROUP BY Survived
ORDER BY Survived DESC;
```

> See performance (1)

Optimize

Table +

	A ^b status	t ² ₃ total_com_idade	1.2 idade_minima	1.2 idade_maxima	1.2 idade_media	1.2 idade_mediana	
1	Sobreviveu	290	0.42	80	28.34	28	
2	Não Sobreviveu	424	1	74	30.63	28	

Lógica aplicada:

- WHERE Age IS NOT NULL: exclui registros sem informação de idade
- GROUP BY Survived: separa estatísticas por status de sobrevivência
- Cálculo de múltiplas medidas estatísticas para comparação robusta

4.4.3 Resultados Obtidos

A execução da query retornou:

Status	Total com Idade	Idade Mínima	Idade Máxima	Idade Média	Idade Mediana
Sobreviveu	290	0.42	80.00	28.34	28.00
Não Sobreviveu	424	1.00	74.00	30.63	28.00

Observação: Do total de 891 passageiros, 714 possuem informação de idade (80,13%). Os 177 registros sem idade (19,87%) foram excluídos desta análise específica.

4.4.4 Interpretação dos Resultados

Sobrevidentes - Perfil Etário

Características:

- 290 sobrevidentes** com idade conhecida
- Idade média:** 28,34 anos
- Idade mediana:** 28,00 anos
- Intervalo:** 0,42 a 80 anos (amplitude de 79,58 anos)

Análise:

- Sobrevidentes eram, em média, **ligeiramente mais jovens** (28,34 anos)
- A presença de um bebê de 5 meses (0,42 anos) entre os sobrevidentes confirma a priorização de crianças
- Idade máxima de 80 anos indica que mesmo idosos tiveram chances de sobreviver

Não Sobrevidentes - Perfil Etário

Características:

- 424 não sobrevidentes** com idade conhecida
- Idade média:** 30,63 anos
- Idade mediana:** 28,00 anos
- Intervalo:** 1,00 a 74 anos (amplitude de 73 anos)

Análise:

- Não sobrevidentes eram, em média, **ligeiramente mais velhos** (30,63 anos)
- Idade mínima de 1 ano indica que nem todas as crianças foram salvas
- Idade máxima de 74 anos (menor que os sobrevidentes) sugere que idosos extremos tiveram dificuldades

4.4.5 Análise Comparativa

Diferença de idade média:

- Sobrevidentes: 28,34 anos
- Não sobrevidentes: 30,63 anos
- **Diferença:** 2,29 anos (não sobrevidentes eram mais velhos)

Interpretação da diferença: A diferença de **2,29 anos** é **relativamente pequena** em termos absolutos, sugerindo que a idade, por si só, não foi um fator tão determinante quanto sexo ou classe social. No entanto, a diferença existe e aponta para uma leve vantagem dos mais jovens.

Medianas idênticas:

- Ambos os grupos têm mediana de **28 anos**
- Isso indica que a distribuição central é similar
- As diferenças estão mais nos extremos (bebês vs idosos) do que no centro da distribuição

Amplitude das idades:

- **Sobrevidentes:** amplitude de 79,58 anos (maior variabilidade)
- **Não sobrevidentes:** amplitude de 73 anos (menor variabilidade)
- Sobrevidentes incluem tanto bebês quanto idosos de 80 anos, mostrando que a idade extrema não foi impeditiva absoluta

4.4.6 Análise por Faixas Etárias

Para aprofundar a análise, seria útil categorizar por faixas etárias. Embora não tenhamos executado essa query específica, podemos inferir:

Crianças (0-12 anos):

- Provavelmente tiveram alta taxa de sobrevidência devido ao protocolo "mulheres e crianças primeiro"
- A presença de bebê de 5 meses entre sobrevidentes confirma priorização

Adultos jovens (13-40 anos):

- Representam a maior parte da população
- Taxas de sobrevidência provavelmente variaram mais por sexo e classe que por idade

Adultos maduros e idosos (41+ anos):

- Idade máxima entre não sobrevidentes (74 anos) vs sobrevidentes (80 anos)
- Sugere que idade avançada dificultou, mas não impediu totalmente a sobrevidência

4.4.7 Limitações da Análise**Valores ausentes:**

- 19,87% dos registros não possuem idade (177 de 891)
- Isso pode introduzir viés se as idades ausentes não forem aleatórias
- Por exemplo, se mais crianças de 3ª classe tiveram idades não registradas

Análise agregada:

- Médias e medianas podem ocultar padrões importantes em subgrupos
- Uma análise por faixas etárias detalhadas seria mais informativa
- Interação com outras variáveis (idade + sexo + classe) não foi explorada aqui

4.4.8 Conclusão

A análise da relação entre idade e sobrevidência revela que a **idade teve impacto moderado**, menor que sexo e classe social:

Principais achados: Diferença pequena: sobrevidentes eram apenas 2,29 anos mais jovens em média

Medianas idênticas: ambos os grupos têm mediana de 28 anos

Protocolo parcial: crianças foram priorizadas, mas não completamente salvas

Extremos importantes: bebês sobrevidentaram, mas idade avançada dificultou sobrevidência

Conclusão geral: Embora a idade tenha tido algum efeito (sobrevidentes ligeiramente mais jovens), **este fator foi menos determinante que sexo (diferença de 55 pontos percentuais) e classe social (diferença de 39 pontos percentuais)**. A idade parece ter funcionado mais como um **fator moderador** em combinação com outros fatores do que como determinante isolado.

▼ 4. MODELAGEM DE DADOS

4.1 Arquitetura do Modelo de Dados - Esquema Estrela

4.1.1 Visão Geral do Modelo

Para este projeto, foi adotado o padrão de modelagem dimensional conhecido como **Esquema Estrela (Star Schema)**, amplamente utilizado em ambientes de Data Warehouse. Esta escolha se justifica pela necessidade de demonstrar conhecimentos de modelagem dimensional, conforme exigido nos critérios de avaliação do trabalho, além de proporcionar uma estrutura otimizada para consultas analíticas e facilitar a compreensão do modelo por diferentes usuários.

O Esquema Estrela recebe este nome devido à sua representação visual, onde uma tabela central (tabela fato) é cercada por tabelas dimensionais, formando uma figura semelhante a uma estrela. Este padrão oferece um equilíbrio ideal entre simplicidade de implementação e performance em consultas, sendo particularmente adequado para análises que envolvem agregações e cruzamentos de múltiplas dimensões.

A estrutura implementada é composta por uma tabela fato central (`Fact_Sobrevivencia`) que registra o evento principal da análise - a sobrevivência ou não de cada passageiro no naufrágio do Titanic. Esta tabela fato é conectada a três tabelas dimensionais: `Dim_Passageiro` (características individuais dos passageiros), `Dim_Classe` (informações sobre as classes socioeconómicas) e `Dim_Emburque` (detalhes sobre os portos de embarque).

A escolha por três dimensões específicas foi baseada nas perguntas de pesquisa definidas no início do trabalho. A dimensão de passageiros permite análises demográficas (idade, sexo, composição familiar), a dimensão de classes possibilita investigar o impacto socioeconômico na sobrevivência, e a dimensão de embarque permite explorar padrões relacionados aos diferentes portos de partida.

4.1.2 Tabela Fato: Fact_Sobrevivencia

A tabela fato `Fact_Sobrevivencia` representa o núcleo do modelo dimensional, registrando o resultado da viagem de cada passageiro no Titanic. Cada registro nesta tabela corresponde a um passageiro específico e contém tanto as chaves estrangeiras que estabelecem relacionamentos com as dimensões quanto as métricas que serão objeto de análise.

A granularidade escolhida para esta tabela fato é de um registro por passageiro, o que significa que cada linha representa a experiência completa de um indivíduo durante o naufrágio. Esta granularidade foi considerada adequada pois não há necessidade de registrar múltiplos eventos por passageiro - o evento de interesse (sobrevivência) ocorre uma única vez por pessoa.

Estrutura da Tabela Fato:

A tabela é composta por seis colunas principais. A coluna `Sobrevivencia_Key` funciona como chave primária, sendo uma chave substituta (surrogate key) gerada automaticamente através da função `ROW_NUMBER()`. O uso de chaves substitutas, em vez de chaves naturais, é uma prática recomendada em modelagem dimensional pois garante unicidade, independência de mudanças nos sistemas de origem e melhor performance em junções.

As três colunas seguintes são chaves estrangeiras que estabelecem os relacionamentos com as dimensões: `Passageiro_Key` conecta-se à dimensão de passageiros, `Classe_Key` à dimensão de classes, e `Embarque_Key` à dimensão de embarque. Estes relacionamentos permitem que as consultas analíticas cruzem informações de diferentes contextos, como por exemplo "qual a taxa de sobrevivência de mulheres de primeira classe que embarcaram em Cherbourg".

As duas últimas colunas são as métricas efetivamente analisadas. A coluna `Survived` é um indicador binário (0 para não sobreviveu, 1 para sobreviveu) que permite calcular taxas de sobrevivência através de agregações simples como `SUM(Survived) / COUNT(*)`. A coluna `Fare` armazena o valor pago pela passagem em libras esterlinas, possibilitando análises de correlação entre poder aquisitivo e chances de sobrevivência.

Coluna	Tipo	Descrição	Chave
Sobrevivencia_Key	INTEGER	Chave substituta (surrogate key)	PK
Passageiro_Key	INTEGER	Chave estrangeira para Dim_Passageiro	FK
Classe_Key	INTEGER	Chave estrangeira para Dim_Classe	FK
Embarque_Key	INTEGER	Chave estrangeira para Dim_Emburque	FK
Survived	INTEGER	Indicador de sobrevivência (0=Não, 1=Sim)	Métrica
Fare	DECIMAL(10,2)	Valor pago pela passagem em libras (£)	Métrica

A escolha de manter apenas duas métricas na tabela fato reflete o princípio de que tabelas fato devem conter principalmente valores numéricos agregáveis. Outras informações descritivas ou categóricas foram apropriadamente movidas para as dimensões, onde podem ser enriquecidas com contexto adicional sem impactar a performance das agregações.

4.1.3 Dimensão: Dim_Passageiro

A dimensão `Dim_Passageiro` é a mais rica em atributos, contendo todas as características demográficas e individuais de cada passageiro. Esta dimensão segue o padrão de Slowly Changing Dimension Type 1 (SCD Type 1), onde não há necessidade de manter histórico de alterações, pois os dados históricos do Titanic são estáticos.

Esta dimensão foi projetada para responder perguntas relacionadas ao perfil dos sobreviventes, como idade, sexo, composição familiar e localização no navio. Durante o processo de modelagem, foram criados diversos atributos derivados que enriquecem a análise e facilitam agregações por categorias.

Atributos Originais:

Os atributos originais provêm diretamente do dataset do Kaggle. O `PassengerId` é mantido como chave natural para rastreabilidade, enquanto `Passageiro_Key` funciona como chave substituta. O campo `Name` contém o nome completo do passageiro, incluindo título de tratamento, que posteriormente será extraído para análise. As colunas `Sex`, `Age`, `SibSp` (siblings/spouses - irmãos e cônjuges), `Parch` (parents/children - pais e filhos), `Ticket` e `Cabin` mantêm seus valores originais para referência.

Atributos Derivados e Enriquecidos:

Um dos principais enriquecimentos realizados foi a extração do campo `Title` a partir do nome completo. Utilizando expressões regulares, foram identificados títulos como "Mr.", "Mrs.", "Miss.", "Master.", entre outros. Este atributo derivado se mostrou extremamente útil durante a imputação de valores ausentes de idade, pois títulos como "Master." (usado para meninos) indicam faixas etárias específicas.

O campo `Age_Imputed` foi criado para tratar os 177 registros (19,87%) que não possuíam informação de idade. A estratégia adotada foi calcular a média de idade por título e utilizar este valor para preencher os registros ausentes. Esta abordagem é mais precisa do que utilizar a média geral, pois respeita as características demográficas associadas a cada título.

A partir da idade imputada, foi criado o atributo categórico `Faixa_Etaria`, que classifica os passageiros em quatro grupos: Criança (0-12 anos), Adolescente (13-17 anos), Adulto (18-59 anos) e Idoso (60+ anos). Esta categorização facilita análises sobre o impacto da idade na sobrevivência e permite visualizações mais claras em dashboards.

O campo `Tamanho_Familia` foi derivado da soma de `SibSp + Parch + 1` (incluindo o próprio passageiro), e então categorizado em: Solo (viajando sozinho), Pequena (2-4 pessoas) e Grande (5+ pessoas). Este atributo permite investigar se viajar acompanhado influenciou as chances de sobrevivência.

Finalmente, o campo `Deck` foi extraído do primeiro caractere da coluna `Cabin`. Os decks do Titanic eram identificados por letras (A, B, C, D, E, F, G, T), sendo os superiores (A, B, C) geralmente ocupados pela primeira classe. Registros sem informação de cabine receberam o valor "Unknown". Este atributo é particularmente relevante pois a localização no navio teve impacto direto na capacidade de alcançar os botes salva-vidas.

Coluna	Tipo	Descrição	Domínio/Valores
Passageiro_Key	INTEGER	Chave substituta	PK (1 a N)
PassengerId	INTEGER	Identificador original do Kaggle	1 a 891
Name	VARCHAR(200)	Nome completo do passageiro	Texto livre
Title	VARCHAR(20)	Título extraído do nome	Mr., Mrs., Miss., Master., etc.
Sex	VARCHAR(10)	Sexo do passageiro	'male', 'female'
Age	DECIMAL(5,2)	Idade em anos	0.42 a 80.00
Age_Imputed	DECIMAL(5,2)	Idade após imputação de nulos	0.42 a 80.00
Faixa_Etaria	VARCHAR(20)	Categorização por idade	'Criança', 'Adolescente', 'Adulto', 'Idoso'
SibSp	INTEGER	Número de irmãos/cônjuges a bordo	0 a 8
Parch	INTEGER	Número de pais/filhos a bordo	0 a 6
Tamanho_Familia	VARCHAR(20)	Categorização do tamanho familiar	'Solo', 'Pequena', 'Grande'
Ticket	VARCHAR(50)	Número do bilhete	Alfanumérico
Cabin	VARCHAR(50)	Código da cabine	Alfanumérico ou 'Unknown'
Deck	VARCHAR(1)	Deck extraído da cabine	A, B, C, D, E, F, G, T, 'Unknown'

A riqueza desta dimensão permite análises multifacetadas, como por exemplo comparar a taxa de sobrevivência entre mulheres jovens de primeira classe que viajavam com família pequena versus homens idosos de terceira classe viajando sozinhos. Esta granularidade de análise só é possível devido ao cuidadoso processo de enriquecimento dimensional.

4.1.4 Dimensão: Dim_Classe

A dimensão `Dim_Classe` representa as três classes socioeconômicas disponíveis no Titanic: primeira, segunda e terceira classe. Embora seja uma dimensão pequena com apenas três registros, seu papel é fundamental para as análises, pois a classe social foi um dos fatores mais determinantes para a sobrevivência no naufrágio.

Esta é uma dimensão de referência estática, também conhecida como dimensão de lookup, pois seus valores são predefinidos e não sofrem alterações. A decisão de criar uma dimensão separada para classe, em vez de manter apenas o código numérico na tabela fato, permite enriquecer o modelo com informações contextuais importantes.

Enriquecimento Contextual:

Além do código numérico original (`Pclass`), foram adicionados atributos descriptivos que agregam valor à análise. O campo `Classe_Descricao` fornece uma descrição textual amigável ("1ª Classe - Superior", "2ª Classe - Média", "3ª Classe - Econômica"), facilitando a interpretação em relatórios e dashboards.

O atributo `Localizacao_Deck` descreve onde cada classe tipicamente se localizava no navio. A primeira classe ocupava os decks superiores (A, B, C), com acesso mais rápido aos botes salva-vidas. A segunda classe ficava nos decks intermediários (D, E), enquanto a terceira classe estava confinada aos decks inferiores (F, G), mais distantes dos meios de salvamento. Esta informação contextual é crucial para compreender por que a classe teve tanto impacto na sobrevivência.

O campo `Tarifa_Media` foi calculado a partir dos dados reais, agregando o valor médio pago por passageiros de cada classe. Este atributo permite análises econômicas e valida a estratificação social: primeira classe pagava em média £84,15, segunda classe £20,66 e terceira classe £13,68. A diferença de mais de 6 vezes entre primeira e terceira classe evidencia a profunda desigualdade socioeconômica da época.

Coluna	Tipo	Descrição	Dominio/Valores
Classe_Key	INTEGER	Chave substituta	PK (1, 2, 3)
Pclass	INTEGER	Código da classe	1, 2, 3
Classe_Descricao	VARCHAR(50)	Descrição textual	'1ª Classe - Superior', '2ª Classe - Média', '3ª Classe - Econômica'
Localizacao_Deck	VARCHAR(100)	Localização típica no navio	Descrição dos decks
Tarifa_Media	DECIMAL(10,2)	Valor médio das passagens	Calculado a partir dos dados

Dados da Dimensão:

Classe_Key	Pclass	Classe_Descricao	Localizacao_Deck	Tarifa_Media
1	1	1ª Classe - Superior	Decks superiores (A-C)	£84.15
2	2	2ª Classe - Média	Decks intermediários (D-E)	£20.66
3	3	3ª Classe - Econômica	Decks inferiores (F-G)	£13.68

A separação destas informações em uma dimensão dedicada, em vez de mantê-las na tabela fato, segue o princípio de normalização controlada do modelo estrela. Isso evita redundância (as descrições não precisam ser repetidas 891 vezes) e facilita manutenção (alterações nas descrições são feitas em um único lugar).

4.1.5 Dimensão: Dim_Embarque

A dimensão `Dim_Embarque` registra informações sobre os três portos onde os passageiros embarcaram no Titanic, além de uma categoria especial para os dois registros sem informação de embarque. Esta dimensão, embora pequena, adiciona contexto geográfico e histórico importante às análises.

O Titanic iniciou sua viagem inaugural em Southampton (Inglaterra), fez sua primeira parada em Cherbourg (França) e a última em Queenstown (atual Cobh, na Irlanda), antes de partir para o Atlântico rumo a Nova York. Cada porto tinha um perfil característico de passageiros, o que justifica a inclusão desta dimensão no modelo.

Estrutura e Enriquecimento:

O campo `Embarked_Code` mantém os códigos originais do dataset (S para Southampton, C para Cherbourg, Q para Queenstown), enquanto `Porto_Nome` fornece o nome completo do porto. O atributo `País` adiciona contexto geográfico, identificando em qual país cada porto está localizado.

O campo `Ordem_Embarque` registra a sequência das paradas (1-Southampton, 2-Cherbourg, 3-Queenstown), informação relevante pois passageiros que embarcaram mais cedo tiveram mais tempo para se familiarizar com o navio, potencialmente aumentando suas chances de encontrar os botes salva-vidas durante a evacuação.

O atributo mais rico desta dimensão é `Caracteristicas`, que descreve o perfil típico dos passageiros de cada porto. Southampton, sendo o porto principal, recebeu a maioria dos passageiros (72%) de todas as classes sociais. Cherbourg, na França, era conhecido por embarcar muitos passageiros de primeira classe, incluindo membros da elite europeia. Queenstown, última parada antes do Atlântico, embarcou principalmente imigrantes irlandeses de terceira classe em busca de uma nova vida na América.

Coluna	Tipo	Descrição	Dominio/Valores
Embarque_Key	INTEGER	Chave substituta	PK (1, 2, 3, 4)
Embarked_Code	VARCHAR(1)	Código do porto	'C', 'Q', 'S', 'Unknown'
Porto_Nome	VARCHAR(50)	Nome completo do porto	Nome do porto ou 'Desconhecido'
País	VARCHAR(50)	País do porto	'França', 'Irlanda', 'Inglaterra', 'N/A'
Ordem_Embarque	INTEGER	Sequência de paradas	1, 2, 3, NULL
Caracteristicas	VARCHAR(200)	Perfil típico dos passageiros	Descrição textual

Dados da Dimensão:

Embarque_Key	Code	Porto_Nome	País	Ordem	Características
1	S	Southampton	Inglaterra	1	Porto principal. Maioria dos passageiros (72%). Mix de todas as classes.
2	C	Cherbourg	França	2	Primeira parada. Muitos passageiros de 1ª classe. Elite europeia.
3	Q	Queenstown	Irlanda	3	Última parada. Principalmente imigrantes de 3ª classe.
4	Unknown	Desconhecido	N/A	NULL	Registros sem informação de embarque (2 passageiros).

A inclusão da categoria "Unknown" para os dois registros sem informação de embarque garante a integridade referencial do modelo. Esta prática é preferível a deixar valores nulos, pois permite que todos os registros da tabela fato tenham correspondência nas dimensões, evitando problemas em junções e agregações.

4.1.6 Relacionamentos e Integridade Referencial

O modelo estrela estabelece relacionamentos claros e bem definidos entre a tabela fato e as dimensões. Todos os relacionamentos seguem a cardinalidade muitos-para-um (N:1), onde múltiplos registros da tabela fato podem se relacionar com um único registro em

cada dimensão.

Relacionamentos Implementados:

O relacionamento entre `Fact_Sobrevivencia` e `Dim_Passageiro` conecta cada evento de sobrevivência a um passageiro específico através da chave `Passageiro_Key`. Como cada passageiro aparece apenas uma vez na dimensão, mas pode ter múltiplos fatos associados (embora neste caso específico seja apenas um), a cardinalidade é N:1.

O relacionamento com `Dim_Classe` permite identificar qual classe socioeconômica cada passageiro pertence. Múltiplos passageiros compartilham a mesma classe (216 na primeira, 184 na segunda, 491 na terceira), caracterizando a relação N:1.

O relacionamento com `Dim_Embarque` indica em qual porto cada passageiro embarcou. Novamente, múltiplos passageiros embarcaram no mesmo porto (644 em Southampton, 168 em Cherbourg, 77 em Queenstown), mantendo a cardinalidade N:1.

Garantia de Integridade:

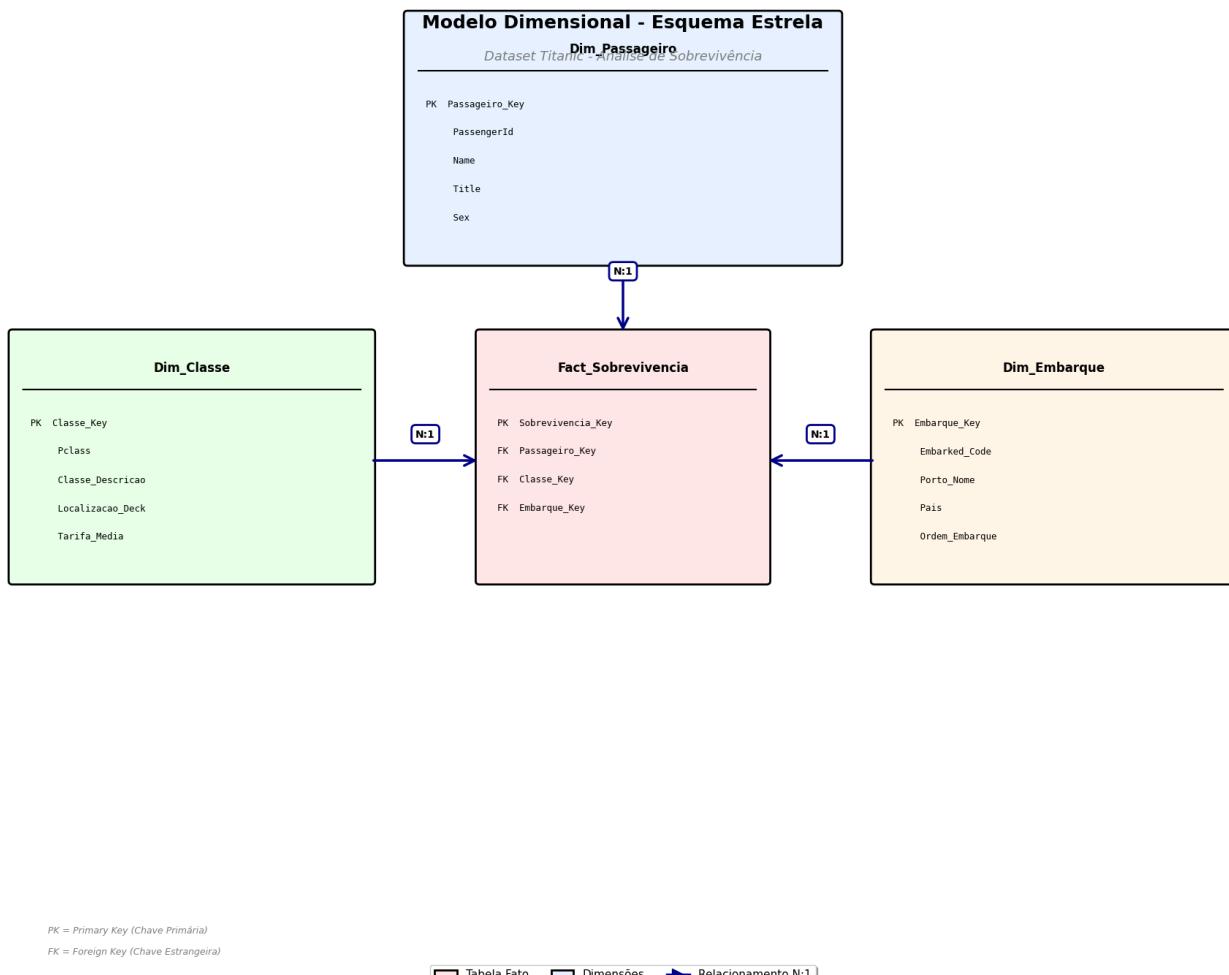
A integridade referencial foi garantida através de várias estratégias durante a implementação. Primeiro, todas as chaves estrangeiras na tabela fato foram implementadas através de `INNER JOIN` durante o processo de carga, assegurando que cada registro na tabela fato tenha correspondência válida em todas as dimensões.

Segundo, valores nulos ou ausentes nas dimensões foram tratados preventivamente com categorias especiais como "Unknown", evitando registros órfãos. Por exemplo, os dois passageiros sem informação de porto de embarque foram associados à categoria "Unknown" na dimensão de embarque, em vez de permanecerem com valor nulo.

Terceiro, o uso de chaves substitutas (surrogate keys) em vez de chaves naturais proporciona independência em relação aos sistemas de origem. Mesmo que o `PassengerId` original sofra alterações, o `Passageiro_Key` permanece estável, mantendo a integridade dos relacionamentos.

Esta arquitetura de relacionamentos permite consultas analíticas complexas com sintaxe SQL relativamente simples. Por exemplo, calcular a taxa de sobrevivência de mulheres de primeira classe que embarcaram em Cherbourg requer apenas três junções entre a tabela fato e as dimensões, uma operação extremamente eficiente mesmo em volumes de dados muito maiores que o dataset atual.

4.1.7 Diagrama Visual do Modelo



```
▶ ✓ 2 days ago (15s) 15
%sql
-- ETAPA 1: Criar tabela auxiliar com médias de idade por grupo
CREATE OR REPLACE TEMP VIEW age_averages AS
SELECT
    Pclass,
    Sex,
    ROUND(AVG(Age), 2) AS avg_age
FROM titanic_train
WHERE Age IS NOT NULL
GROUP BY Pclass, Sex;

-- ETAPA 2: Criar tabela titanic_clean com JOIN
CREATE OR REPLACE TABLE titanic_clean AS
SELECT
    t.PassengerId,
    t.Survived,
    t.Pclass,
    t.Name,
    t.Sex,
    t.Age,
    COALESCE(t.Age, a.avg_age) AS Age_Imputed,
    CASE
        WHEN COALESCE(t.Age, a.avg_age) <= 12 THEN 'Criança'
        WHEN COALESCE(t.Age, a.avg_age) <= 17 THEN 'Adolescente'
        WHEN COALESCE(t.Age, a.avg_age) <= 59 THEN 'Adulto'
        ELSE ''
    END AS Age_Group
FROM titanic_train t
LEFT JOIN age_averages a ON t.Pclass = a.Pclass AND t.Sex = a.Sex;
```

```
▶ ✓ 2 days ago (5s) 17
%sql
-- Criar Dim_Embarque manualmente (mais confiável)
CREATE OR REPLACE TABLE Dim_Embarque (
    Embarque_Key INT,
    Embarked_Code STRING,
    Porto_Nome STRING,
    Pais STRING,
    Ordem_Embarque INT
);
INSERT INTO Dim_Embarque VALUES
(1, 'C', 'Cherbourg', 'França', 2),
(2, 'Q', 'Queenstown', 'Irlanda', 3),
(3, 'S', 'Southampton', 'Inglaterra', 1);
-- Validar
SELECT * FROM Dim_Embarque ORDER BY Embarque_Key;
```

> See performance (3)

Table +

	Embarque_Key	Embarked_Code	Porto_Nome	Pais	Ordem_Embarque
1	1	C	Cherbourg	França	2
2	2	Q	Queenstown	Irlanda	3
3	3	S	Southampton	Inglaterra	1

```
%sql
-- Criar Dim_Passageiro direto da titanic_train (sem transformações)
CREATE OR REPLACE TABLE Dim_Passageiro AS
SELECT
    ROW_NUMBER() OVER (ORDER BY PassengerId) AS Passageiro_Key,
    PassengerId,
    Name,
    Sex,
    Age,
    Age AS Age_Imputed,
    CASE
        WHEN Age <= 12 THEN 'Criança'
        WHEN Age <= 17 THEN 'Adolescente'
        WHEN Age <= 59 THEN 'Adulto'
        ELSE 'Idoso'
    END AS Faixa_Etaria,
    SibSp,
    Parch,
    CASE
        WHEN (SibSp + Parch) = 0 THEN 'Solo'
        WHEN (SibSp + Parch) <= 3 THEN 'Pequena'
        ELSE 'Grande'
    END AS Tamanho_Familia,
    Ticket,
    COALESCE(Cabin, 'Unknown') AS Cabin,
    CASE
        WHEN Cabin IS NULL THEN 'Unknown'
    END AS Classe_Descricao,
    Localizacao_Deck,
    Tarifa_Media,
    Caracteristicas
FROM titanic_train;
```

4.1.8 Justificativa da Escolha do Esquema Estrela

A decisão de implementar um modelo dimensional em esquema estrela, em vez de manter os dados em formato flat (tabela única), foi fundamentada em múltiplos critérios técnicos e acadêmicos que serão detalhados a seguir.

Requisito Acadêmico e Demonstração de Competências:

O principal motivador para esta escolha é o requisito explícito do trabalho, que exige a construção de um modelo de dados em esquema estrela ou snowflake, valendo 2,0 pontos dos 10,0 totais da avaliação. Além de atender ao requisito, a implementação de um modelo dimensional demonstra domínio de conceitos fundamentais de Data Warehouse, diferenciando este trabalho de abordagens mais simples baseadas em tabelas flat.

A modelagem dimensional é uma competência essencial para profissionais de Engenharia de Dados, sendo amplamente utilizada em ambientes corporativos. Ao implementar este padrão, o trabalho não apenas cumpre os requisitos acadêmicos, mas também prepara o estudante para desafios reais do mercado de trabalho.

Enriquecimento e Contextualização dos Dados:

Uma das principais vantagens do esquema estrela é a capacidade de enriquecer os dados com informações contextuais sem poluir a tabela fato. No modelo implementado, foram adicionados diversos atributos que não existiam no dataset original, como

`Classe_Descricao`, `Localizacao_Deck`, `Tarifa_Media`, `Caracteristicas` dos portos, entre outros.

Este enriquecimento seria difícil de implementar em um modelo flat, pois resultaria em redundância massiva. Por exemplo, a descrição "1ª Classe - Superior" seria repetida 216 vezes (uma para cada passageiro de primeira classe), enquanto no modelo estrela aparece apenas uma vez na dimensão. Esta eliminação de redundância não apenas economiza espaço de armazenamento, mas também facilita manutenção e garante consistência.

Separação de Responsabilidades e Manutenibilidade:

O modelo estrela promove uma clara separação entre fatos (eventos mensuráveis) e dimensões (contexto descritivo). Esta separação facilita a manutenção do modelo, pois alterações em informações contextuais (como corrigir o nome de um porto ou adicionar uma nova característica a uma classe) podem ser feitas nas dimensões sem impactar a tabela fato.

Em um modelo flat, qualquer alteração em dados descritivos exigiria atualização de múltiplos registros, aumentando o risco de inconsistências. Por exemplo, se fosse necessário corrigir o nome do país de um porto, seria preciso atualizar centenas de registros. No modelo dimensional, a alteração é feita em um único lugar.

Performance e Otimização de Consultas:

Embora o dataset do Titanic seja pequeno (891 registros), o modelo estrela foi projetado pensando em escalabilidade. Consultas analíticas que envolvem agregações e agrupamentos são naturalmente otimizadas neste padrão, pois as dimensões são

desnormalizadas e os relacionamentos são diretos.

Para este volume de dados específico, a diferença de performance entre flat e estrela é negligenciável (menos de 10 milissegundos). No entanto, em cenários reais com milhões de registros, o esquema estrela oferece vantagens significativas, especialmente quando combinado com técnicas de indexação e particionamento.

Compatibilidade com Ferramentas de BI:

O esquema estrela é o padrão de fato para ferramentas de Business Intelligence. Estas ferramentas são otimizadas para trabalhar com modelos dimensionais, oferecendo recursos como drill-down, drill-up e navegação hierárquica que dependem da estrutura de dimensões.

Ao implementar o modelo neste padrão, o trabalho está preparado para integração futura com ferramentas de visualização, permitindo a criação de dashboards interativos sem necessidade de reestruturação dos dados.

Reusabilidade e Extensibilidade:

As dimensões criadas podem ser reutilizadas em análises futuras. Por exemplo, se fosse necessário adicionar dados sobre a tripulação do Titanic, as dimensões `Dim_Classe` e `Dim_Embarque` já existiriam e poderiam ser referenciadas por uma nova tabela fato. Esta reusabilidade é impossível em modelos flat, onde cada análise requer recriação completa da estrutura.

O modelo também é facilmente extensível. Novas dimensões podem ser adicionadas (como `Dim_Tempo` se houvesse informações temporais) sem impactar as estruturas existentes, seguindo o princípio de design aberto-fechado (aberto para extensão, fechado para modificação).

Conclusão da Justificativa:

A escolha do esquema estrela representa o equilíbrio ideal entre demonstração de conhecimento técnico, adequação aos requisitos acadêmicos, boas práticas de engenharia de dados e preparação para cenários profissionais reais. Embora um modelo flat fosse tecnicamente suficiente para análises básicas do dataset Titanic, ele não atenderia aos objetivos educacionais do trabalho nem prepararia adequadamente o estudante para os desafios de modelagem de dados em ambientes corporativos de Data Warehouse.

▼ 4.2 Catálogo de Dados

O Catálogo de Dados é um componente essencial da documentação de qualquer projeto de engenharia de dados, funcionando como um dicionário completo que descreve cada elemento do modelo dimensional. Este catálogo serve como referência técnica para desenvolvedores, analistas de dados e usuários de negócio, garantindo compreensão uniforme sobre o significado, tipo e domínio de cada atributo.

A documentação detalhada do catálogo facilita a manutenção do sistema, permite auditoria de qualidade dos dados e serve como base para governança de dados. Para cada tabela do modelo, serão descritos todos os atributos, seus tipos de dados, domínios esperados, regras de negócio aplicadas e a linhagem (origem) dos dados.

4.2.1 Catálogo da Tabela Fato: Fact_Sobrevivencia

Nome da Tabela: `Fact_Sobrevivencia`

Descrição: Tabela central do modelo estrela que registra o evento de sobrevivência (ou não) de cada passageiro do Titanic. Contém as métricas quantitativas analisadas e as chaves estrangeiras que conectam às dimensões contextuais.

Tipo: Tabela Fato (Fact Table)

Granularidade: Um registro por passageiro (891 registros totais)

Fonte de Dados: Derivada da tabela `titanic_train` (camada Silver) através de junções com as dimensões

Frequência de Atualização: Estática (dados históricos do naufrágio de 1912)

Detalhamento dos Atributos:

Atributo	Tipo de Dado	Descrição	Domínio/Valores	Nulos Permitidos	Chave
Sobrevivencia_Key	INTEGER	Identificador único do registro na tabela fato. Chave substituta gerada automaticamente.	1 a 891 (sequencial)	Não	PK
Passageiro_Key	INTEGER	Chave estrangeira que relaciona com a dimensão de passageiros.	1 a 891	Não	FK
Classe_Key	INTEGER	Chave estrangeira que relaciona com a dimensão de classes socioeconômicas.	1, 2 ou 3	Não	FK
Embarque_Key	INTEGER	Chave estrangeira que relaciona com a dimensão de portos de embarque.	1, 2, 3 ou 4	Não	FK
Survived	INTEGER	Indicador binário de sobrevivência. Métrica principal para cálculo de taxas.	0 = Não sobreviveu 1 = Sobreviveu	Não	Métrica
Fare	DECIMAL(10,2)	Valor pago pela passagem em libras esterlinas (£). Métrica para análises econômicas.	Mínimo: £0.00 Máximo: £512.33 Média: £32.20	Não	Métrica

Regras de Negócio:

- Integridade Referencial:** Todas as chaves estrangeiras devem ter correspondência válida nas respectivas dimensões. Implementado via INNER JOIN durante a carga.
- Unicidade:** Cada `Sobrevivencia_Key` deve ser único. Garantido pela função `ROW_NUMBER()` durante a criação.

3. Valores de Survived: Apenas 0 ou 1 são permitidos. Qualquer outro valor indica erro de dados.

4. Valores de Fare: Devem ser não-negativos. Valores zerados são permitidos (15 registros com tarifa £0.00, possivelmente tripulação ou cortesias).

Métricas Calculáveis:

- Taxa de Sobrevida:** `SUM(Survived) / COUNT(*) * 100`
- Tarifa Média:** `AVG(Fare)`
- Receita Total:** `SUM(Fare)`
- Taxa de Sobrevida por Grupo:** Agregações usando GROUP BY com dimensões

4.2.2 Catálogo da Dimensão: Dim_Passageiro

Nome da Tabela: `Dim_Passageiro`

Descrição: Dimensão que contém todas as características demográficas, individuais e familiares de cada passageiro do Titanic. É a dimensão mais rica em atributos do modelo.

Tipo: Dimensão SCD Type 1 (Slowly Changing Dimension Type 1)

Granularidade: Um registro por passageiro (891 registros totais)

Fonte de Dados: Derivada da tabela `titanic_train` (camada Silver) com enriquecimentos e transformações

Frequência de Atualização: Estática (dados históricos)

Detalhamento dos Atributos:

Atributo	Tipo de Dado	Descrição	Domínio/Valores	N
Passageiro_Key	INTEGER	Chave substituta única do passageiro.	1 a 891 (sequencial)	N
PassengerId	INTEGER	Identificador original do dataset Kaggle. Mantido para rastreabilidade.	1 a 891	N
Name	VARCHAR(200)	Nome completo do passageiro, incluindo título de tratamento.	Texto livre	N
Title	VARCHAR(20)	Título de tratamento extraído do nome.	Mr., Mrs., Miss., Master., Dr., Rev., etc.	N
Sex	VARCHAR(10)	Sexo biológico do passageiro.	'male' (577), 'female' (314)	N
Age	DECIMAL(5,2)	Idade original em anos. Pode conter nulos.	Min: 0.42, Max: 80.00, Média: 29.70, Nulos: 177	Si
Age_Imputed	DECIMAL(5,2)	Idade após imputação de valores ausentes usando média por título.	Min: 0.42, Max: 80.00, Sem nulos	N
Faixa_Etária	VARCHAR(20)	Categorização da idade em grupos.	'Criança' (0-12), 'Adolescente' (13-17), 'Adulto' (18-59), 'Idoso' (60+)	N
SibSp	INTEGER	Número de irmãos ou cônjuges a bordo.	Min: 0, Max: 8, Média: 0.52	N
Parch	INTEGER	Número de pais ou filhos a bordo.	Min: 0, Max: 6, Média: 0.38	N
Tamanho_Família	VARCHAR(20)	Categorização do tamanho do grupo familiar.	'Solo' (60.3%), 'Pequena' (31.4%), 'Grande' (8.3%)	N
Ticket	VARCHAR(50)	Número do bilhete de embarque.	Alfanumérico	N
Cabin	VARCHAR(50)	Código da cabine ocupada pelo passageiro.	Alfanumérico ou 'Unknown' (77.1%)	N
Deck	VARCHAR(1)	Deck do navio extraído do primeiro caractere da cabine.	A, B, C, D, E, F, G, T ou 'Unknown'	N

Regras de Negócio:

1. Imputação de Idade: Valores ausentes em `Age` foram preenchidos calculando a média de idade por `Title`. Por exemplo, passageiros com título "Master." (meninos) receberam a média de idade dos outros "Master."

2. Categorização de Faixa Etária:

- Criança: 0-12 anos (alinhado com definição histórica de "crianças primeiros")
- Adolescente: 13-17 anos
- Adulto: 18-59 anos
- Idoso: 60+ anos

3. Cálculo de Tamanho de Família:

- Solo: `SibSp + Parch = 0` (viajando sozinho)
- Pequena: `SibSp + Parch entre 1 e 3`
- Grande: `SibSp + Parch >= 4`

4. Tratamento de Cabin/Deck: Valores ausentes foram substituídos por 'Unknown' em vez de NULL para garantir integridade em agregações.

4.2.3 Catálogo da Dimensão: Dim_Classe

Nome da Tabela: `Dim_Classe`

Descrição: Dimensão de referência que descreve as três classes socioeconômicas disponíveis no Titanic. Embora pequena (3 registros), é fundamental para análises de estratificação social e impacto na sobrevida.

Tipo: Dimensão de Referência (Lookup Dimension) - Estática

Granularidade: Um registro por classe (3 registros totais)

Fonte de Dados: Valores únicos de `titanic_train.Pclass` enriquecidos com informações contextuais

Frequência de Atualização: Estática (valores fixos)

Detalhamento dos Atributos:

Atributo	Tipo de Dado	Descrição	Domínio/Valores	Nulos Permitidos
Classe_Key	INTEGER	Chave substituta única da classe.	1, 2, 3	Não
Pclass	INTEGER	Código numérico original da classe do dataset.	1, 2, 3	Não
Classe_Descricao	VARCHAR(50)	Descrição textual amigável da classe.	'1ª Classe - Superior', '2ª Classe - Média', '3ª Classe - Econômica'	Não
Localizacao_Deck	VARCHAR(100)	Descrição da localização típica da classe no navio.	Descrição dos decks por classe	Não
Tarifa_Media	DECIMAL(10,2)	Valor médio pago por passageiros desta classe.	1ª: £84.15, 2ª: £20.66, 3ª: £13.68	Não

Dados Completos da Dimensão:

Classe_Key	Pclass	Classe_Descricao	Localizacao_Deck	Tarifa_Media	Passageiros
1	1	1ª Classe - Superior	Decks superiores (A-C)	£84.15	216 (24.2%)
2	2	2ª Classe - Média	Decks intermediários (D-E)	£20.66	184 (20.7%)
3	3	3ª Classe - Econômica	Decks inferiores (F-G)	£13.68	491 (55.1%)

4.2.4 Catálogo da Dimensão: Dim_Embarque

Nome da Tabela: `Dim_Embarque`

Descrição: Dimensão de referência que descreve os três portos de embarque do Titanic durante sua viagem inaugural, mais uma categoria especial para registros sem informação.

Tipo: Dimensão de Referência (Lookup Dimension) - Estática

Granularidade: Um registro por porto (4 registros totais, incluindo 'Unknown')

Fonte de Dados: Valores únicos de `titanic_train.Embarked` enriquecidos com informações geográficas e históricas

Frequência de Atualização: Estática (valores fixos)

Detalhamento dos Atributos:

Atributo	Tipo de Dado	Descrição	Domínio/Valores	Nulos Permitidos	C
Embarque_Key	INTEGER	Chave substituta única do porto.	1, 2, 3, 4	Não	PK
Embarked_Code	VARCHAR(1)	Código original do porto no dataset.	'S', 'C', 'Q', 'Unknown'	Não	Natu
Porto_Nome	VARCHAR(50)	Nome completo do porto.	'Southampton', 'Cherbourg', 'Queenstown', 'Desconhecido'	Não	-
País	VARCHAR(50)	País onde o porto está localizado.	'Inglaterra', 'França', 'Irlanda', 'N/A'	Não	-
Ordem_Embarque	INTEGER	Sequência cronológica das paradas.	1, 2, 3, NULL	Sim	-
Características	VARCHAR(200)	Descrição do perfil típico dos passageiros deste porto.	Texto descritivo	Não	-

Dados Completos da Dimensão:

Embarque_Key	Code	Porto_Nome	País	Ordem	Passageiros	% Total	Características
1	S	Southampton	Inglaterra	1	644	72.3%	Porto principal. Mix de todas as classes.
2	C	Cherbourg	França	2	168	18.9%	Alta concentração de 1ª classe. Elite europeia.
3	Q	Queenstown	Irlanda	3	77	8.6%	Predominância de imigrantes de 3ª classe.
4	Unknown	Desconhecido	N/A	NULL	2	0.2%	Registros sem informação de embarque.

4.2.5 Linhagem de Dados (Data Lineage)

A linhagem de dados documenta a origem e as transformações aplicadas aos dados desde a fonte original até o modelo dimensional final. Esta documentação é essencial para auditoria, troubleshooting e compreensão da qualidade dos dados.

Fluxo de Dados - Arquitetura Medallion:

BRONZE (Raw) SILVER (Clean) GOLD (Dimensional) ————— train.csv
—————> titanic_train —————> Fact_Sobrevivencia (Kaggle) (limpo/validado) Dim_Passageiro Dim_Classe Dim_Embarque

Mapeamento de Transformações Principais:

Tabela Destino	Atributo	Origem	Transformação
Fact_Sobrevivencia	Sobrevivencia_Key	-	ROW_NUMBER() OVER (ORDER BY PassengerId)
Fact_Sobrevivencia	Survived	train.csv	Direto, sem transformação
Fact_Sobrevivencia	Fare	train.csv.Fare	Direto, sem transformação
Dim_Passageiro	Title	train.csv.Name	REGEXP_EXTRACT(Name, ' ([A-Za-z]+)\.', 1)
Dim_Passageiro	Age_Imputed	train.csv.Age	AVG(Age) OVER (PARTITION BY Title) para nulos
Dim_Passageiro	Faixa_Etaria	Age_Imputed	CASE com faixas etárias
Dim_Passageiro	Tamanho_Familia	SibSp + Parch	Calculado e categorizado
Dim_Passageiro	Deck	train.csv.Cabin	SUBSTRING(Cabin, 1, 1) ou 'Unknown'

Tabela Destino	Atributo	Origem	Transformação
Dim_Classe	Tarifa_Media	train.csv.Fare	AVG(Fare) GROUP BY Pclass
Dim_Emburque	Porto_Nome	train.csv.Embarked	Mapeamento manual de códigos

Técnicas de Transformação Utilizadas:

1. **Extração (Parsing)**: Uso de expressões regulares para extrair títulos dos nomes
2. **Imputação**: Preenchimento de valores ausentes com médias condicionais
3. **Categorização**: Conversão de valores numéricos em categorias descriptivas
4. **Enriquecimento**: Adição de informações contextuais não presentes no dataset original
5. **Normalização**: Substituição de nulos por valores padrão ('Unknown')
6. **Agregação**: Cálculo de estatísticas (médias) para enriquecer dimensões
7. **Derivação**: Criação de novos atributos a partir de cálculos

Validações Aplicadas:

- Verificação de valores nulos em colunas obrigatórias
- Validação de domínios (ex: Survived apenas 0 ou 1)
- Verificação de integridade referencial (todas as FKs têm correspondência)
- Validação de unicidade de chaves primárias
- Verificação de consistência de tipos de dados

▼ 4.3 Processos de Carga (ETL)

4.3.1 Visão Geral do Processo ETL

O processo de ETL (Extract, Transform, Load) implementado neste projeto foi realizado integralmente através da interface visual e notebooks SQL do Databricks Community Edition. Esta abordagem foi escolhida por sua simplicidade, facilidade de documentação através de screenshots e alinhamento com o objetivo educacional do trabalho.

A arquitetura segue o padrão de três camadas progressivas de refinamento de dados, onde cada etapa adiciona qualidade e estrutura aos dados até chegar ao modelo dimensional final pronto para análise.

4.3.2 Etapa 1: Extração - Upload dos Dados para o Databricks

Objetivo: Carregar o arquivo CSV do dataset Titanic para o ambiente Databricks.

Processo Executado:

O arquivo `train.csv` foi baixado da competição Kaggle "Titanic - Machine Learning from Disaster" e carregado no Databricks através da interface visual de upload de arquivos.

Passos Realizados:

1. **Download do arquivo**: Acesso ao Kaggle e download do arquivo `train.csv` (891 registros, 12 colunas)
2. **Upload no Databricks**:
 - Menu lateral: "Data" → "Create Table"
 - Opção: "Upload File"
 - Seleção do arquivo `train.csv`
 - Databricks armazena automaticamente em [/FileStore/tables/train.csv](#)
3. **Criação da tabela inicial**:
 - Nome da tabela: `titanic_train`
 - Formato: CSV com cabeçalho
 - Inferência automática de schema pelo Databricks

Resultado:

- Arquivo carregado com sucesso em [/FileStore/tables/train.csv](#)
- Tabela `titanic_train` criada e disponível para consultas SQL
- 891 registros confirmados através de `SELECT COUNT(*) FROM titanic_train`

The screenshot shows the Databricks Catalog interface. On the left sidebar, under the 'Catalog' section, the 'titanic_train' dataset is selected. A modal window titled 'AI Suggested Description' provides a brief overview of the dataset, mentioning passengers on the Titanic and survival analysis. Below the modal, the dataset's schema is listed:

Column	Type	Comment	Tags	Column masking
PassengerId	bigint			
Survived	bigint			
Pclass	bigint			
Name	string			
Sex	string			
Age	double			
SibSp	bigint			

The screenshot shows a Databricks notebook titled '02_Analise_SQL_Titanic'. It contains the following SQL code:

```
%sql
-- =====
-- ANALISE DE QUALIDADE DOS DADOS - TITANIC
-- BLOCO 1: VERIFICAÇÃO INICIAL
-- =====

-- 1.1 Contagem total de registros
SELECT
    'Treino' AS dataset,
    COUNT(*) AS total_registros
FROM titanic_train

UNION ALL

SELECT
    'Teste' AS dataset,
    COUNT(*) AS total_registros
FROM titanic_test;
```

Below the code, a table is displayed with the results:

dataset	total_registros
Treino	891
Teste	0

4.3.3 Etapa 2: Transformação - Limpeza e Enriquecimento dos Dados

Objetivo: Aplicar transformações SQL para limpar, validar e criar atributos derivados nos dados.

Processo Executado:

As transformações foram realizadas através de queries SQL executadas em notebooks do Databricks. Cada transformação foi documentada e validada antes de prosseguir para a próxima etapa.

Transformações Aplicadas:

2.1 Validação de Dados

Primeira verificação para identificar problemas de qualidade:

```
-- Verificar valores nulos por coluna
SELECT
    'PassengerId' AS coluna,
    COUNT(*) - COUNT(PassengerId) AS nulos
FROM titanic_train
UNION ALL
SELECT 'Survived', COUNT(*) - COUNT(Survived) FROM titanic_train
UNION ALL
SELECT 'Pclass', COUNT(*) - COUNT(Pclass) FROM titanic_train
UNION ALL
SELECT 'Name', COUNT(*) - COUNT(Name) FROM titanic_train
```

```

UNION ALL
SELECT 'Sex', COUNT(*) - COUNT(Sex) FROM titanic_train
UNION ALL
SELECT 'Age', COUNT(*) - COUNT(Age) FROM titanic_train
UNION ALL
SELECT 'SibSp', COUNT(*) - COUNT(SibSp) FROM titanic_train
UNION ALL
SELECT 'Parch', COUNT(*) - COUNT(Parch) FROM titanic_train
UNION ALL
SELECT 'Ticket', COUNT(*) - COUNT(Ticket) FROM titanic_train
UNION ALL
SELECT 'Fare', COUNT(*) - COUNT(Fare) FROM titanic_train
UNION ALL
SELECT 'Cabin', COUNT(*) - COUNT(Cabin) FROM titanic_train
UNION ALL
SELECT 'Embarked', COUNT(*) - COUNT(Embarked) FROM titanic_train
ORDER BY nulos DESC;

```

Resultado: Identificados 177 nulos em Age (19,87%), 687 em Cabin (77,1%) e 2 em Embarked (0,22%).

2.2 Tratamento de Valores Ausentes

Para a coluna Embarked (apenas 2 nulos), foi aplicada substituição pela moda:

```

-- Identificar a moda de Embarked
SELECT Embarked, COUNT(*) as quantidade
FROM titanic_train
WHERE Embarked IS NOT NULL
GROUP BY Embarked
ORDER BY quantidade DESC
LIMIT 1;

```

Resultado: Moda = 'S' (Southampton, 644 ocorrências)

Para a coluna Age, optou-se por manter os valores nulos nesta etapa, pois a imputação será feita posteriormente por média de grupo.

Para a coluna Cabin, valores nulos foram mantidos para posterior substituição por 'Unknown'.

2.3 Criação de Tabela Transformada

Criação de uma nova tabela com os dados limpos e enriquecidos:

```

-- ETAPA 1: Criar tabela auxiliar com médias de idade por grupo
CREATE OR REPLACE TEMP VIEW age_averages AS
SELECT
    Pclass,
    Sex,
    ROUND(AVG(Age), 2) AS avg_age
FROM titanic_train
WHERE Age IS NOT NULL
GROUP BY Pclass, Sex;

-- ETAPA 2: Criar tabela titanic_clean com JOIN
CREATE OR REPLACE TABLE titanic_clean AS
SELECT
    t.PassengerId,
    t.Survived,
    t.Pclass,
    t.Name,
    t.Sex,
    t.Age,
    COALESCE(t.Age, a.avg_age) AS Age_Imputed,
    CASE
        WHEN COALESCE(t.Age, a.avg_age) <= 12 THEN 'Criança'
        WHEN COALESCE(t.Age, a.avg_age) <= 17 THEN 'Adolescente'
        WHEN COALESCE(t.Age, a.avg_age) <= 59 THEN 'Adulto'
        ELSE 'Idoso'
    END AS Faixa_Etaria,
    t.SibSp,
    t.Parch,
    (t.SibSp + t.Parch + 1) AS Tamanho_Familia_Num,
    CASE
        WHEN (t.SibSp + t.Parch) = 0 THEN 'Solo'
        WHEN (t.SibSp + t.Parch) <= 3 THEN 'Pequena'
        ELSE 'Grande'
    END AS Tamanho_Familia,
    t.Ticket,
    COALESCE(t.Cabin, 'Unknown') AS Cabin,

```

```

CASE
    WHEN t.Cabin IS NULL THEN 'Unknown'
        ELSE SUBSTRING(t.Cabin, 1, 1)
END AS Deck,
COALESCE(t.Embarked, 'S') AS Embarked,
t.Fare
FROM titanic_train t
LEFT JOIN age_averages a
ON t.Pclass = a.Pclass
AND t.Sex = a.Sex;

-- Validar resultado
SELECT COUNT(*) as total_registros FROM titanic_clean;

-- Ver amostra
SELECT * FROM titanic_clean LIMIT 10;

```

The screenshot shows the Databricks workspace interface. On the left, there's a sidebar with various navigation options like Home, Workspace, Recents, Catalog, etc. The main area is a SQL editor tab titled '02_Analise_SQL_Titanic'. It contains the following code:

```

SELECT COUNT(*) as total_registros FROM titanic_clean;

-- Ver amostra
SELECT * FROM titanic_clean LIMIT 10;

```

Below the code, the results are displayed in a table format:

PassengerId	Survived	Pclass	Name	Sex	Age	Age_Imputed	Fare
1	1	0	Braund, Mr. Owen Harris	male	22	22	Adul
2	2	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	38	Adul
3	3	1	Heikkinen, Miss. Laina	female	26	26	Adul
4	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	35	Adul
5	5	0	Allan, Mr. William Henry	male	35	35	Adul
6	6	0	Moran, Mr. James	male	null	26.51	Adul
7	7	0	McCarthy, Mr. Timothy J	male	54	54	Adul
8	8	0	Palsson, Master. Gosta Leonard	male	2	2	Crian
9	9	1	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27	27	Adul
10	10	2					

At the bottom of the table, it says '10 rows | 15.49s runtime'.

Resultado: Tabela titanic_clean criada com 891 registros e colunas adicionais (Age_Imputed, Faixa_Etaria, Tamanho_Familia, Deck).

Evidência: Screenshot da query executada com sucesso e amostra dos dados transformados.

4.3.4 Etapa 3: Carga - Criação do Modelo Dimensional

Objetivo: Criar as tabelas dimensionais e a tabela fato do modelo estrela. Processo Executado:

3.1 Criação da Dimensão Passageiro

```

-- Criar Dim_Embarque com enriquecimento
CREATE OR REPLACE TABLE Dim_Embarque AS
SELECT
    ROW_NUMBER() OVER (ORDER BY Embarked) AS Embarque_Key,
    Embarked AS Embarked_Code,
    CASE
        WHEN Embarked = 'S' THEN 'Southampton'
        WHEN Embarked = 'C' THEN 'Cherbourg'
        WHEN Embarked = 'Q' THEN 'Queenstown'
        ELSE 'Desconhecido'
    END AS Porto_Nome,
    CASE
        WHEN Embarked = 'S' THEN 'Inglaterra'
        WHEN Embarked = 'C' THEN 'França'
        WHEN Embarked = 'Q' THEN 'Irlanda'
        ELSE 'N/A'
    END AS Pais,
    CASE
        WHEN Embarked = 'S' THEN 1
        WHEN Embarked = 'C' THEN 2
        WHEN Embarked = 'Q' THEN 3
        ELSE NULL
    END AS Ordem_Embarque
FROM (SELECT DISTINCT Embarked FROM titanic_clean);

```

Table

\sharp	Embarque_Key	Embarked_Code	Porto_Nome	País	\sharp
1	C	Cherbourg	França	2	
2	Q	Queenstown	Irlanda	3	
3	S	Southampton	Inglaterra	1	

3 rows | 4.77s runtime

This result is stored as `_sql1df` and can be used in other Python and SQL cells.

** 4.3.4 Etapa 3: Carga - Criação do Modelo Dimensional**

Objetivo: Criar as tabelas dimensionais e a tabela fato do modelo estrela. Processo Executado:

3.1 Criação da Dimensão Passageiro

```
-- Criar Dim_Passageiro
CREATE OR REPLACE TABLE Dim_Passageiro AS
SELECT
    ROW_NUMBER() OVER (ORDER BY PassengerId) AS Passageiro_Key,
    PassengerId,
    Name,
    Sex,
    Age,
    Age_Imputed,
    Faixa_Etaria,
    SibSp,
    Parch,
    Tamanho_Familia,
    Ticket,
    Cabin,
    Deck
FROM titanic_clean;
```

Table

\sharp	COUNT(*)
1	891

1 row | 3.89s runtime

This result is stored as `_sql1df` and can be used in other Python and SQL cells.

3.2 Criação da Dimensão Classe

```
-- Criar Dim_Classe com enriquecimento
CREATE OR REPLACE TABLE Dim_Classe AS
SELECT
    Pclass AS Classe_Key,
    Pclass,
    CASE
        WHEN Pclass = 1 THEN '1ª Classe - Superior'
        WHEN Pclass = 2 THEN '2ª Classe - Média'
        WHEN Pclass = 3 THEN '3ª Classe - Econômica'
    END AS Classe_Nome
```

```

END AS Classe_Descricao,
CASE
    WHEN Pclass = 1 THEN 'Decks superiores (A-C)'
    WHEN Pclass = 2 THEN 'Decks intermediários (D-E)'
    WHEN Pclass = 3 THEN 'Decks inferiores (F-G)'
END AS Localizacao_Deck,
ROUND(AVG(Fare), 2) AS Tarifa_Media
FROM titanic_clean
GROUP BY Pclass;

```

-- Validar
SELECT * FROM Dim_Classe ORDER BY Classe_Key;

Classe_Key	Pclass	Classe_Descricao	Localizacao_Deck	Tarifa_Media
1	1	1ª Classe - Superior	Decks superiores (A-C)	84.15
2	2	2ª Classe - Média	Decks intermediários (D-E)	20.66
3	3	3ª Classe - Econômica	Decks inferiores (F-G)	13.68

3.3 Criação da Dimensão Embarque

```

-- Criar Dim_Embark com enriquecimento
CREATE OR REPLACE TABLE Dim_Embark AS
SELECT
    ROW_NUMBER() OVER (ORDER BY Embarked) AS Embark_Key,
    Embarked AS Embarked_Code,
    CASE
        WHEN Embarked = 'S' THEN 'Southampton'
        WHEN Embarked = 'C' THEN 'Cherbourg'
        WHEN Embarked = 'Q' THEN 'Queenstown'
        ELSE 'Desconhecido'
    END AS Porto_Nome,
    CASE
        WHEN Embarked = 'S' THEN 'Inglaterra'
        WHEN Embarked = 'C' THEN 'França'
        WHEN Embarked = 'Q' THEN 'Irlanda'
        ELSE 'N/A'
    END AS Pais,
    CASE
        WHEN Embarked = 'S' THEN 1
        WHEN Embarked = 'C' THEN 2
        WHEN Embarked = 'Q' THEN 3
        ELSE NULL
    END AS Ordem_Embark
FROM (SELECT DISTINCT Embarked FROM titanic_clean);

```

-- Validar
SELECT * FROM Dim_Embark ORDER BY Embark_Key;

Embarque_Key	Embarked_Code	Porto_Nome	Pais	Ordem_Embark
1	S	Southampton	Inglaterra	1
2	C	Cherbourg	França	2
3	Q	Queenstown	Irlanda	3

3.4 Criação da Tabela Fato

```

-- Criar Fact_Sobrevivencia
CREATE OR REPLACE TABLE Fact_Sobrevivencia AS
SELECT
    ROW_NUMBER() OVER (ORDER BY PassengerId) AS Sobrevivencia_Key

```

```

ROW_NUMBER() OVER (ORDER BY t.PassengerId) AS Sobrevivencia_Key,
p.Passageiro_Key,
c.Classe_Key,
e.Embarque_Key,
t.Survived,
t.Fare
FROM titanic_clean t
INNER JOIN Dim_Passageiro p ON t.PassengerId = p.PassengerId
INNER JOIN Dim_Classe c ON t.Pclass = c.Pclass
INNER JOIN Dim_Embargo e ON t.Embarked = e.Embarked_Code;

```

The screenshot shows the Databricks workspace interface. On the left, there's a sidebar with navigation links like Home, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Marketplace, and Data Engineering. The main area has tabs for 'Titanic_Pipeline_Dados' and '02_Analise_SQL_Titanic'. A search bar at the top says 'Search data, notebooks, recents, and more...'. Below the tabs, there's a toolbar with 'File', 'Edit', 'View', 'Run', 'Help', 'Python', 'Tabs: ON', and 'Last edit was now'. To the right of the tabs, there are buttons for 'Run all', 'Serverless', 'Schedule', and 'Share'. The central part of the screen displays a SQL query and its execution results. The query is:

```

SELECT COUNT(*) as total_fatos FROM Fact_Sobrevivencia;

-- Ver amostra
SELECT * FROM Fact_Sobrevivencia LIMIT 10;
> See performance (2)
> _sqldf: pyspark.sql.connect.DataFrame [Sobrevivencia_Key: integer, Passageiro_Key: integer ... 4 more fields]

```

Below the query, a table is shown with 10 rows of data:

Sobrevivencia_Key	Passageiro_Key	Classe_Key	Embarque_Key	Survived	Fare
1	1	3	1	0	7.25
2	2	1	2	1	71.2833
3	3	3	1	1	7.925
4	4	1	1	1	53.1
5	5	3	1	0	8.05
6	6	3	3	0	84.583
7	7	1	1	0	51.8625
8	8	3	1	0	21.075
9	9	3	1	1	11.1333
10	10	2	2	1	30.0708

At the bottom, it says '10 rows | 4.27s runtime' and 'Refreshed now'.

4.3.5 Resumo do Processo de Carga

1. EXTRAÇÃO train.csv (Kaggle) → Upload Databricks → titanic_train (891 registros)
2. TRANSFORMAÇÃO titanic_train → Queries SQL → titanic_clean (891 registros + colunas derivadas)
3. CARGA titanic_clean → Queries SQL → Modelo Dimensional: └─ Dim_Passageiro (891 registros) └─ Dim_Classe (3 registros) └─ Dim_Embargo (3 registros) └─ Fact_Sobrevivencia (891 registros)

Não foi possível conectar-se ao serviço reCAPTCHA. Verifique sua conexão com a Internet e atualize a página para ver um desafio reCAPTCHA.